Visualisation avec R

Laurent Rouvière

Janvier 2020

Présentation

- Prérequis : niveau avancé en **R** - bases en statistique et programmation
- Objectifs :
  - Comprendre l'importance de la visualisation en science des données
  - Visualiser des données, des modèles et des résultats
  - Découvrir quelques packages de visualisation en R
- Ressources:
  - slides et notebook R disponibles à l'url https://lrouviere.github.io/VISU/

Complément

Workshop Shiny en février.

Pourquoi un cours de visualisation ?

- Données de plus en plus complexes
- Modèles de plus en plus complexes
- Interprétations des résultats de plus en plus complexes.

Pourquoi un cours de visualisation ?

- Données de plus en plus complexes
- Modèles de plus en plus complexes
- Interprétations des résultats de plus en plus complexes.

Conséquence

La visualisation se révèle cruciale tout au long d'une étude statistique.

Pourquoi un cours de visualisation ?

- Données de plus en plus complexes
- Modèles de plus en plus complexes
- Interprétations des résultats de plus en plus complexes.

Conséquence

La visualisation se révèle cruciale tout au long d'une étude statistique.

- Besoin de visualiser pour :
  - décrire les données
  - calibrer les modèles
  - présenter les résultats de l'étude.

Plan

- (au moins) 2 façons d'appréhender la visualisation :
  1. Méthodes/modèles statistiques : PCA, LDA, arbres...
  2. Outils : packages R.

Plan

- (au moins) 2 façons d'appréhender la visualisation :
  1. Méthodes/modèles statistiques : PCA, LDA, arbres...
  2. Outils : packages R.

- Dans ce cours, on va présenter quelques outils R :
  1. ggplot2 : un package R pour visualiser les données (3-4h).
  2. Cartes avec ggmap, sf et leaflet (3-4h).
  3. Visualisation intéractive avec rAmCharts, leaflet et shiny (3-4h).

Plan

- (au moins) 2 façons d'appréhender la visualisation :
  1. Méthodes/modèles statistiques : PCA, LDA, arbres...
  2. Outils : packages R.

- Dans ce cours, on va présenter quelques outils R :
  1. ggplot2 : un package R pour visualiser les données (3-4h).
  2. Cartes avec ggmap, sf et leaflet (3-4h).
  3. Visualisation intéractive avec rAmCharts, leaflet et shiny (3-4h).

Remarque

De plus en plus de packages R sont dédiés à la visualisation.

Introduction

ggplot2

```
> library(tidyverse) #ggplot2 dans tidyverse
> ggplot(iris)+aes(x=Species,y=Sepal.Length)+geom_boxplot()
```

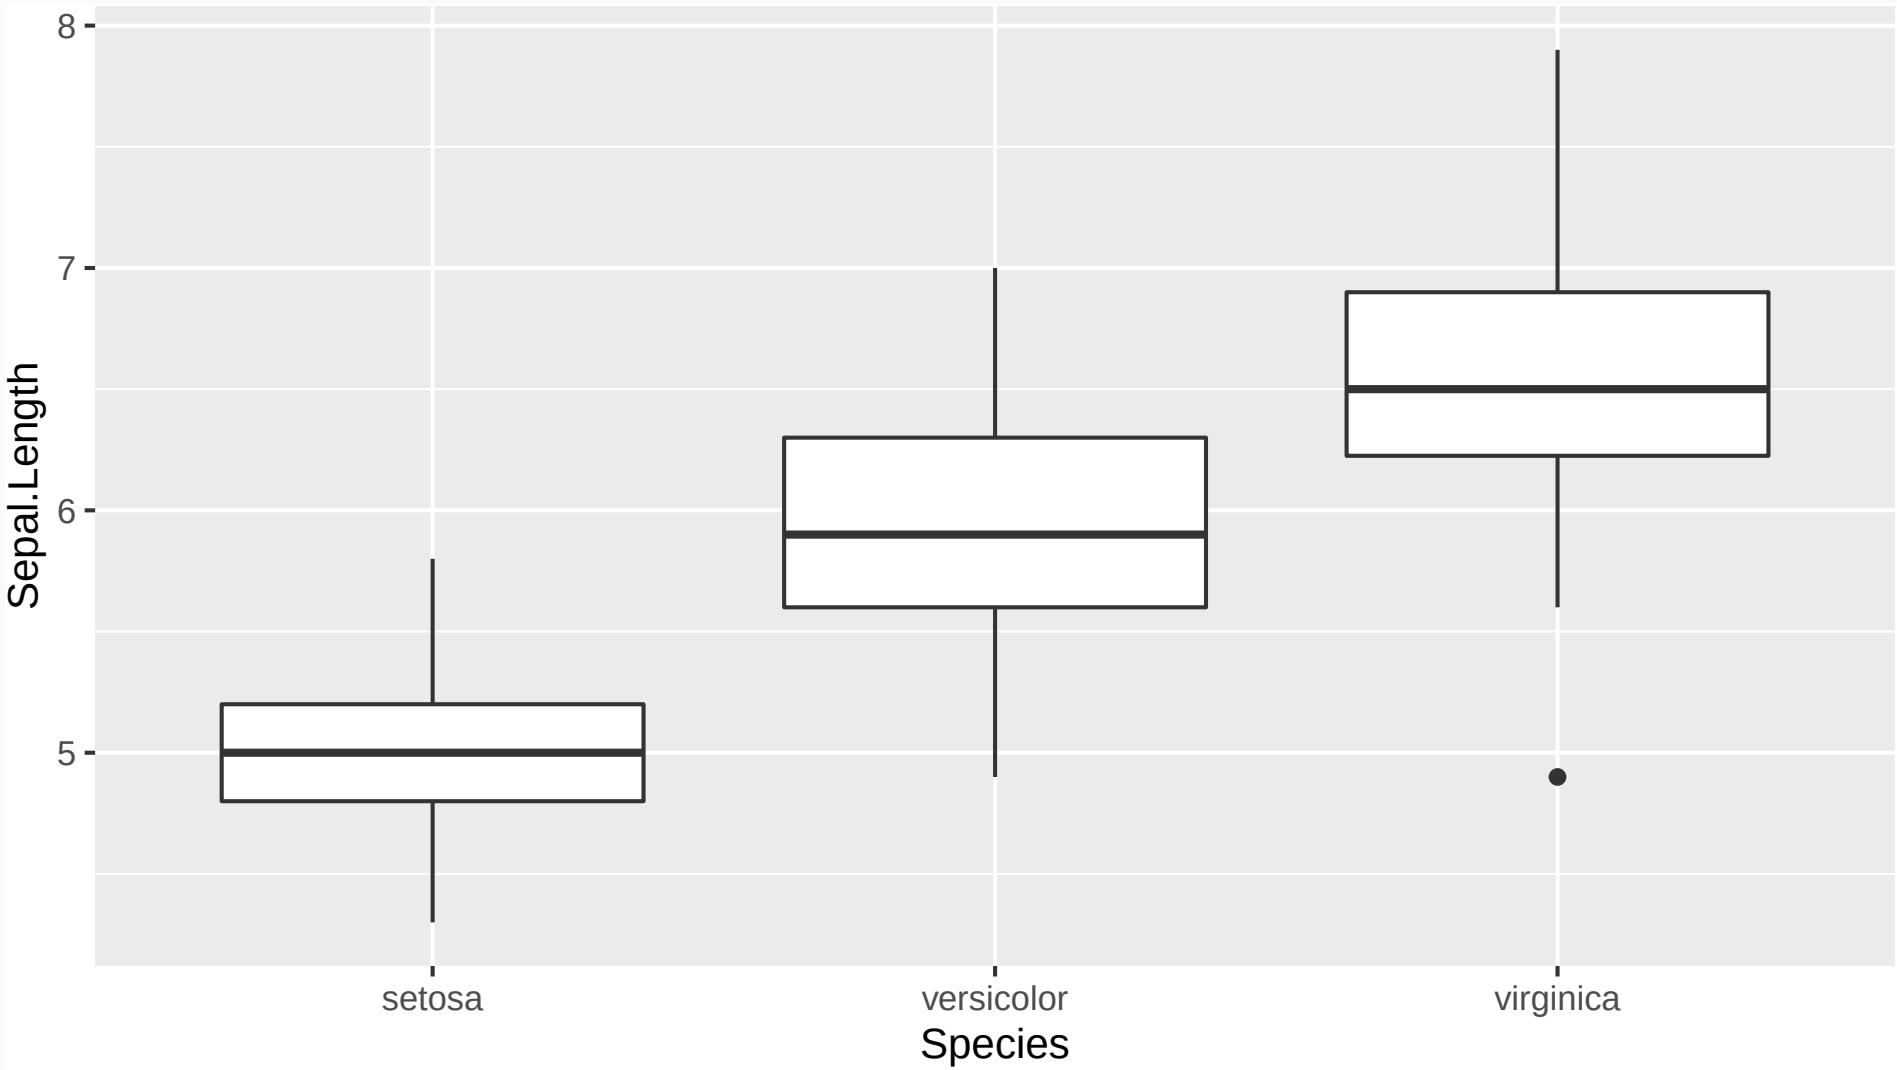

Une carte de températures avec ggmap

```
> library(ggmap)
> ggmap(fond)+geom_polygon(data=Test5,
+   aes(y=Latitude,x=Longitude,fill=temp1,color=temp1,
+       group=dept),size=1)+
+   scale_fill_continuous(low="yellow",high="red")+
+   scale_color_continuous(low="yellow",high="red")
```

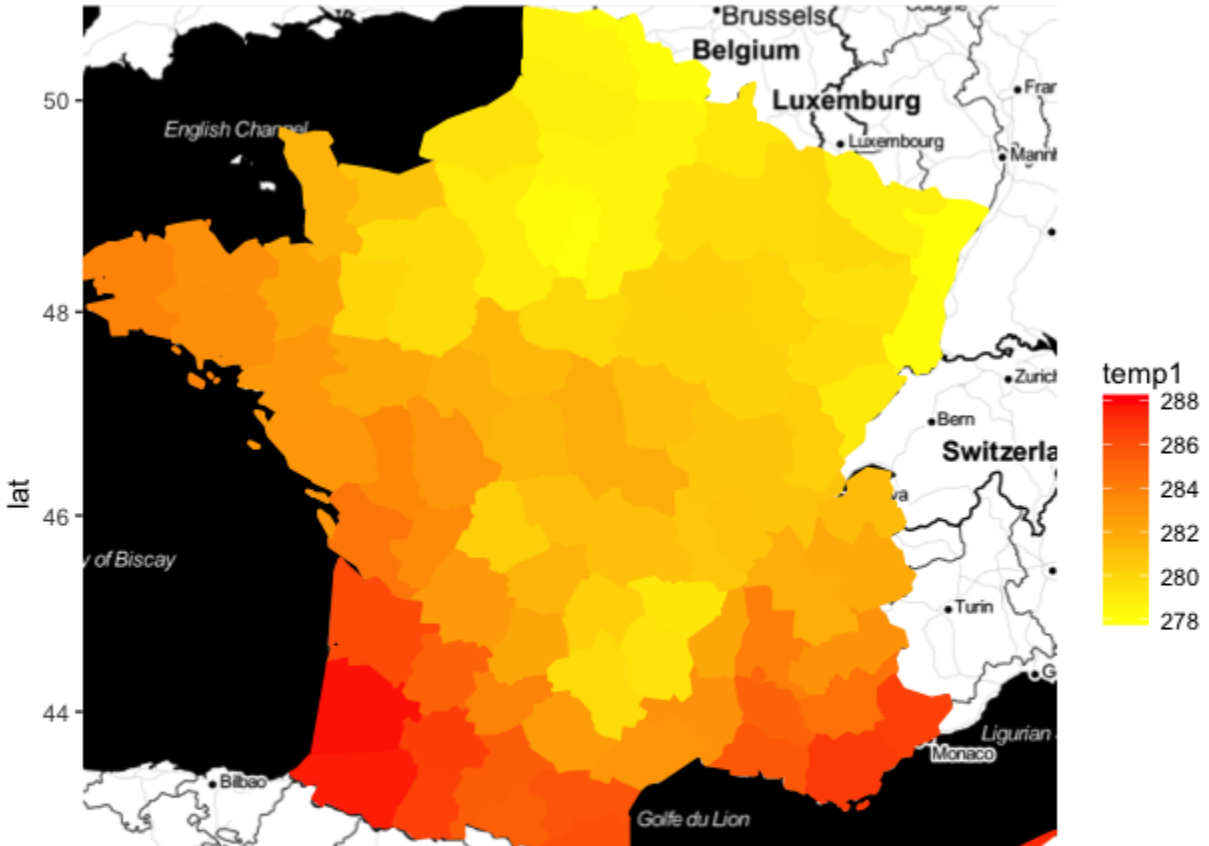

Visu intéractive avec rAmCharts

```
> library(rAmCharts)
> amBoxplot(Sepal.Length~Species,data=iris)
```

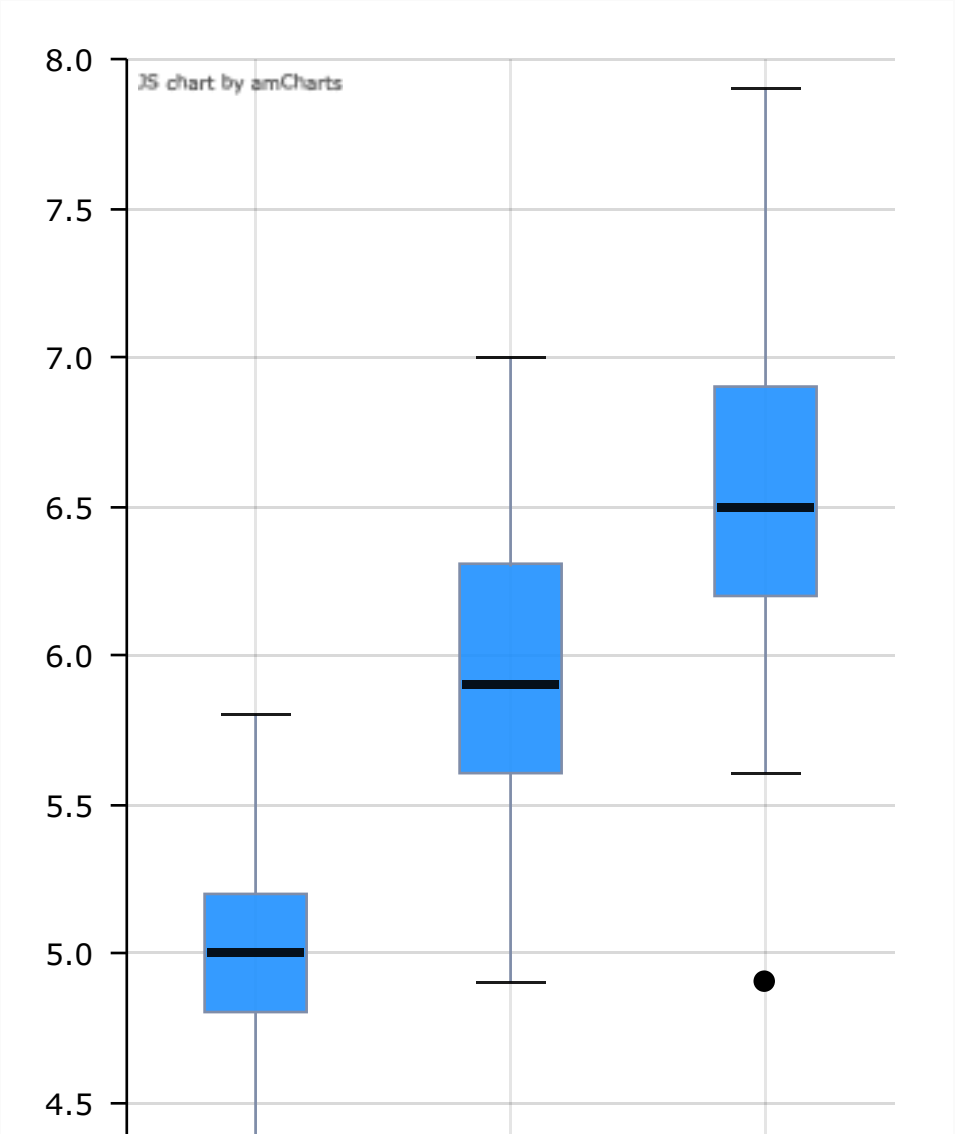

Applications web intéractives avec shiny

- Shiny est un package R qui permete de faire “facilement” des applications web intéractives.

- Example: stations velib à Rennes
  https://data.rennesmetropole.fr/page/home/

```
> library(shiny)
> runApp('desc_app.R')
> runApp('app_velib.R')
> runApp('trace_roc_app.R')
```

Visualisation avec ggplot2

La fonction plot (rappels)

- Fonction générique pour représenter (presque) tous les types de données.
- Pour un nuage de points, il suffit de renseigner un vecteur pour l'axe des x, et un autre vecteur pour celui des y.

```
> x <- seq(-2*pi,2*pi,by=0.1)
> plot(x,sin(x),type="l",xlab="x",ylab="sin(x)")
> abline(h=c(-1,1))
```

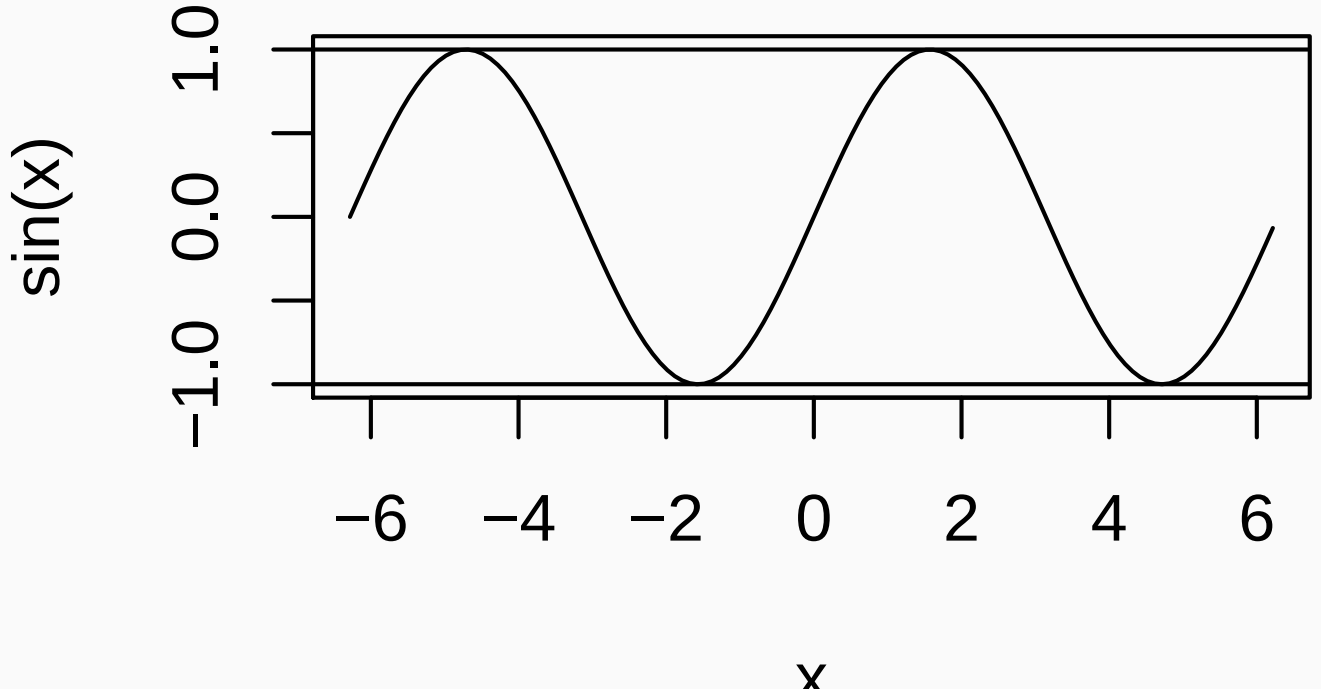

Graphes classiques pour visualiser des variables

- Histogramme pour une variable continue, diagramme en barres pour une variable qualitative.
- Nuage de points pour 2 variables continues.
- Boxplot pour une distribution continue.

Graphes classiques pour visualiser des variables

- Histogramme pour une variable continue, diagramme en barres pour une variable qualitative.
- Nuage de points pour 2 variables continues.
- Boxplot pour une distribution continue.

Constat (positif)

Il existe une fonction R pour toutes les représentations.

Nuage de points sur un jeu de données

```
> plot(Sepal.Length~Sepal.Width,data=iris)
```

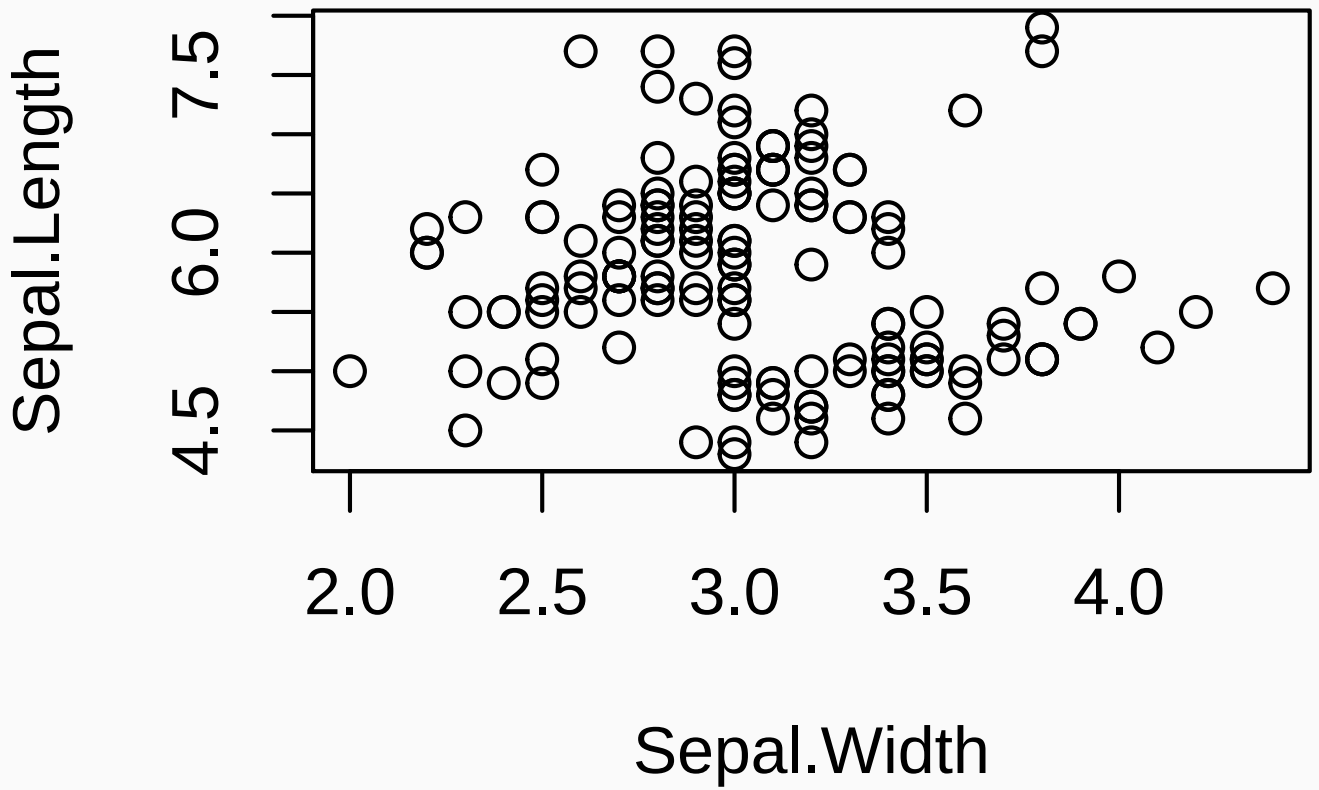


```
> #same as
> plot(iris$Sepal.Width,iris$Sepal.Length)
```

Histogramme (variable continue)

```
> hist(iris$Sepal.Length,col="red")
```

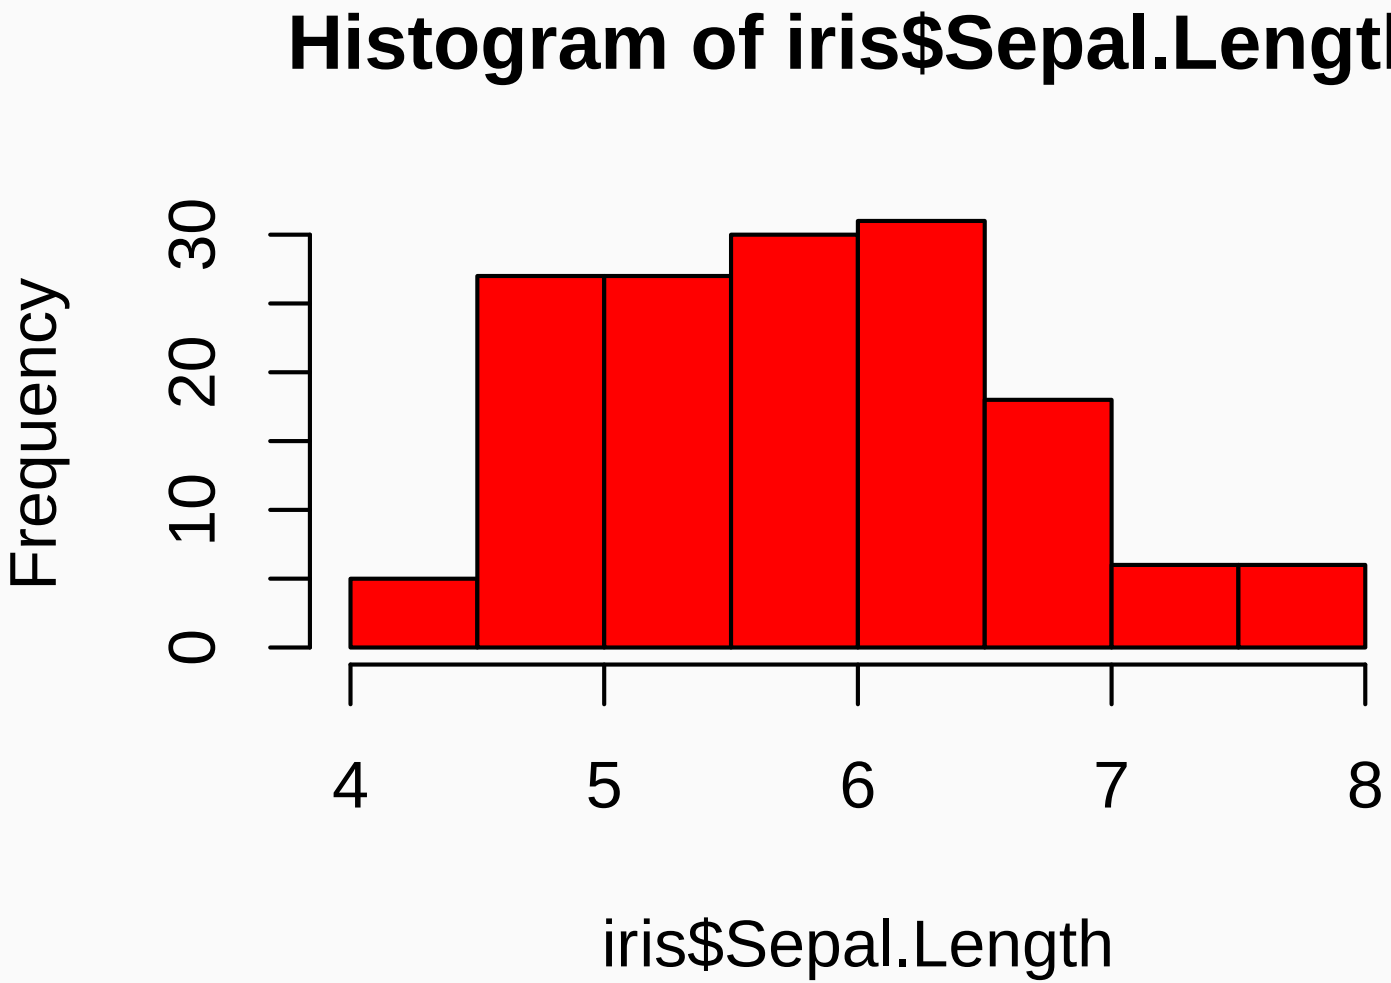

Diagramme en barres (variable qualitative)

```
> barplot(table(iris$Species))
```

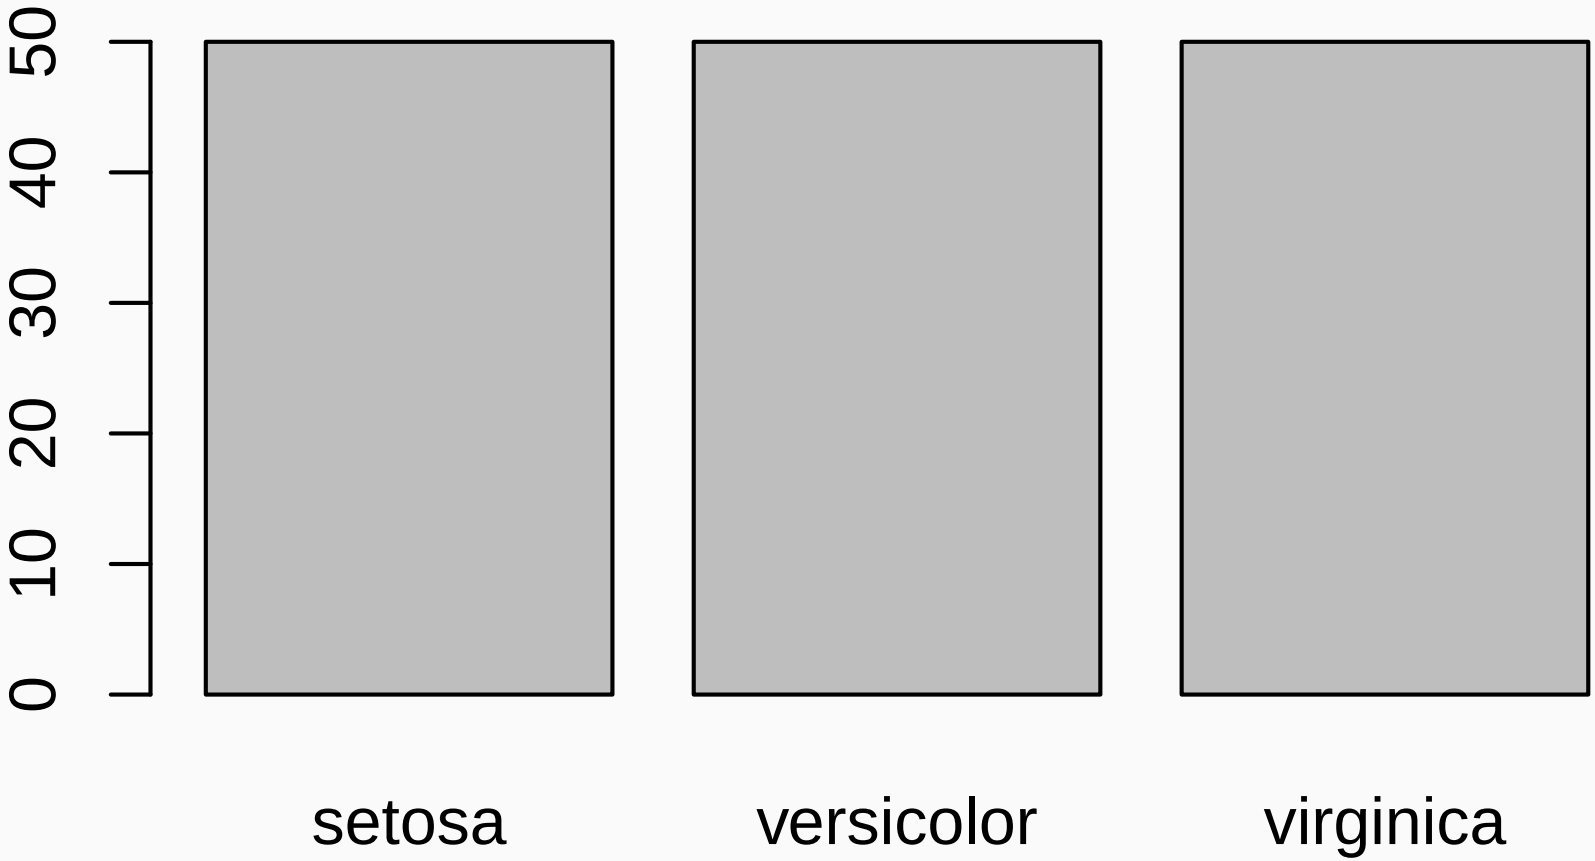

Boxplot (distribution)

```
> boxplot(Sepal.Length~Species,data=iris)
```

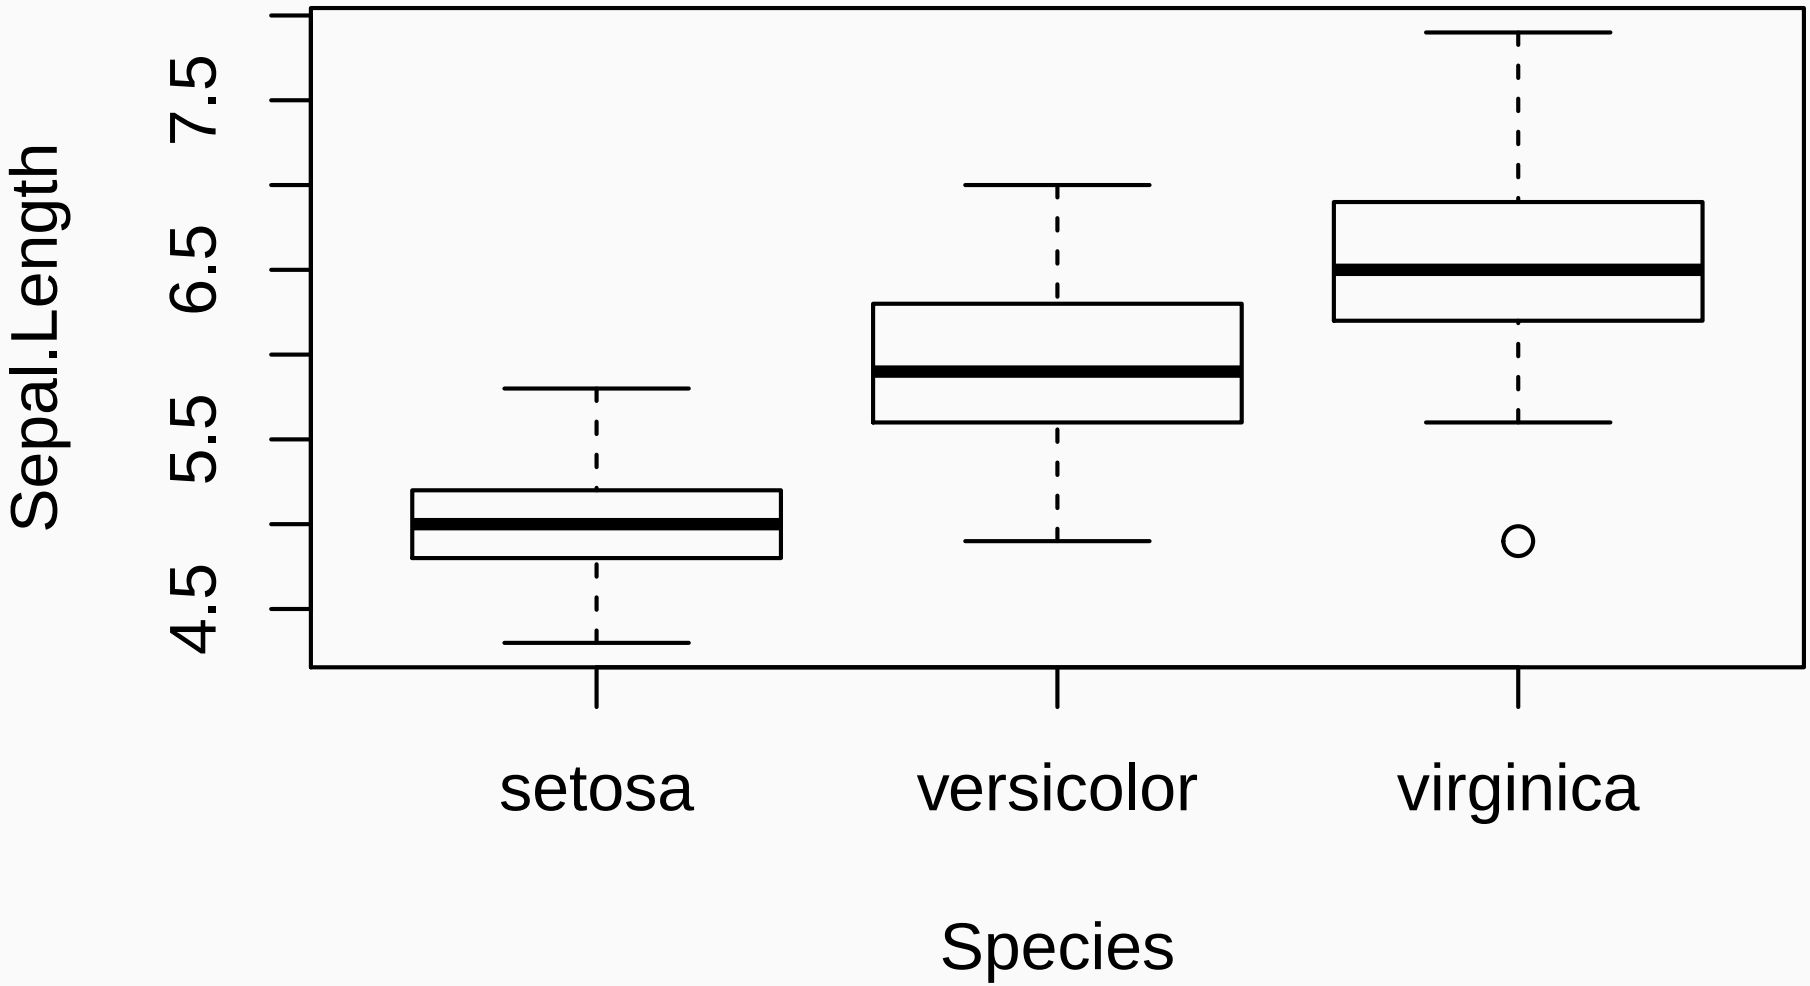

- ggplot2 permet de faire des graphes R en s'appuyant sur une grammaire des graphiques (équivalent de **dplyr** pour manipuler les données).
- Les graphes produits sont agréables à regarder (pas toujours le cas avec les graphes conventionnels).
- La grammaire ggplot permet d'obtenir des graphes "complexes" avec une syntaxe claire et lisible.

Pour un tableau de données fixé, un graphe est défini comme une succession de **couches**. Il faut toujours spécifier :

- les données
- les variables à représenter
- le type de représentation (nuage de points, boxplot...).

Pour un tableau de données fixé, un graphe est défini comme une succession de **couches**. Il faut toujours spécifier :

- les données
- les variables à représenter
- le type de représentation (nuage de points, boxplot...).

Les graphes ggplot sont construits à partir de ces couches. On indique

- les données avec **ggplot**
- les variables avec **aes** (aesthetics)
- le type de représentation avec **geom_**

La grammaire

Les principaux verbes sont

- **Data (ggplot)** : les données, un dataframe ou un tibble.
- **Aesthetics (aes)** : façon dont les variables doivent être représentées.
- **Geometrics (geom_...)** : type de représentation.
- **Statistics (stat_...)** : spécifier les transformations des données.
- **Scales (scale_...)** : modifier certains paramètres du graphe (changer de couleurs, de taille...).

Tous ces éléments sont séparés par un $+$.

Un exemple

```
> ggplot(iris)+aes(x=Sepal.Length,y=Sepal.Width)+geom_point()
```

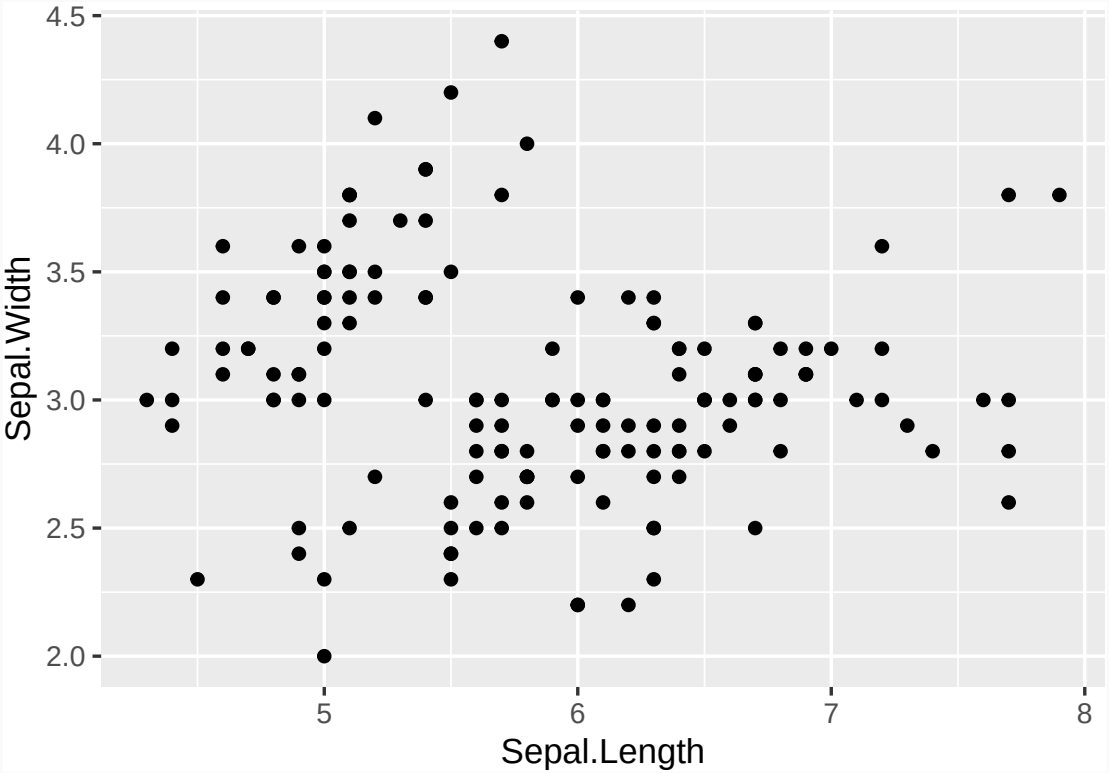

Couleur et taille

```
> ggplot(iris)+aes(x=Sepal.Length,y=Sepal.Width)+
+   geom_point(color="blue",size=2)
```

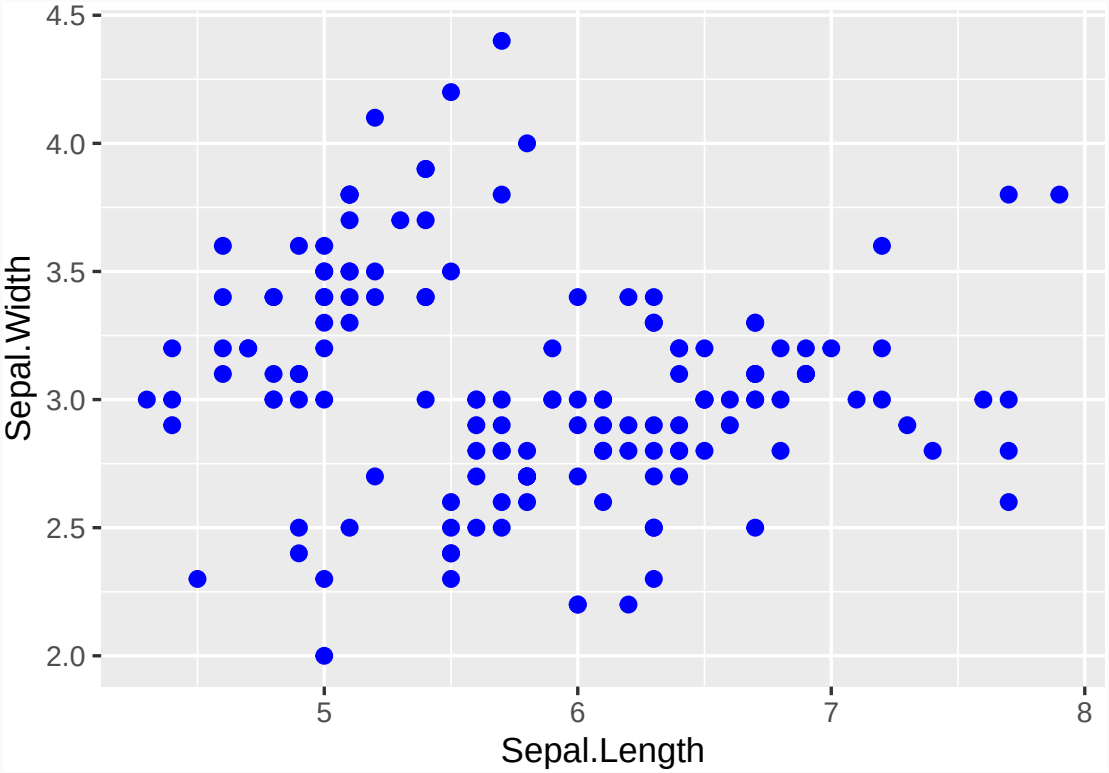

Couleur avec une variable qualitative

```
> ggplot(iris)+aes(x=Sepal.Length,y=Sepal.Width,
+                  color=Species)+geom_point()
```

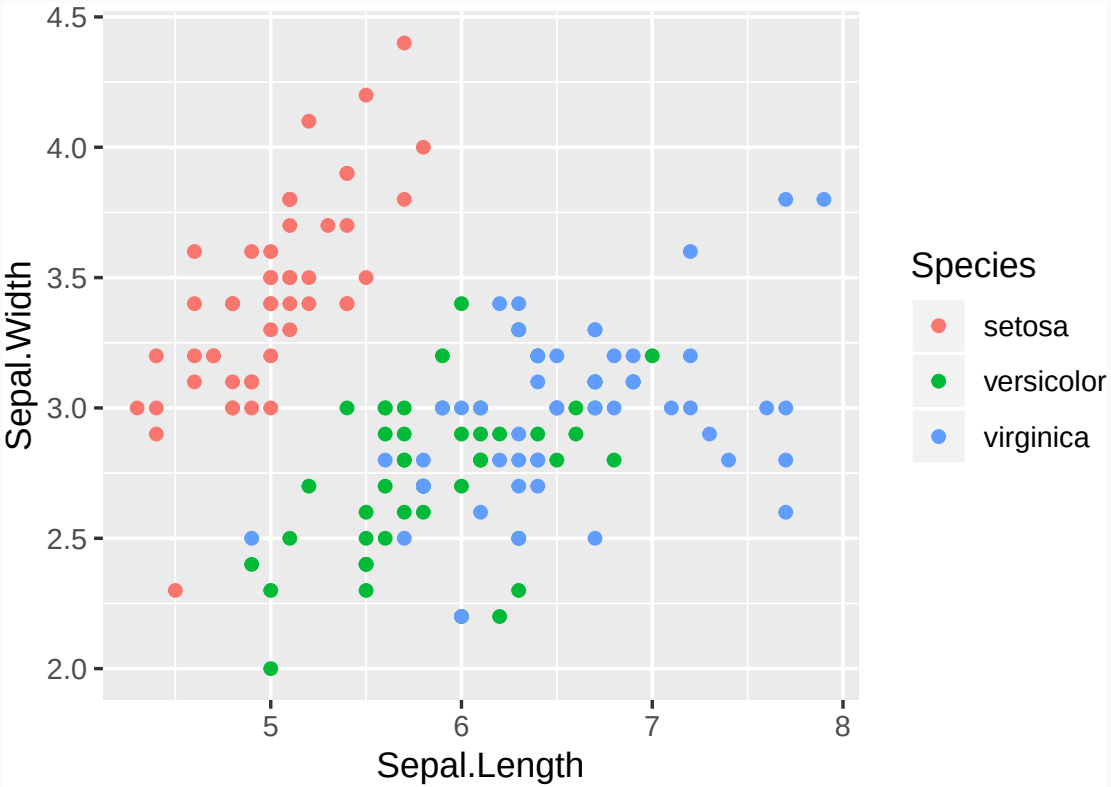

Couleur avec une variable continue

```
> ggplot(iris)+aes(x=Sepal.Length,y=Sepal.Width,
+                  color=Petal.Width)+geom_point()
```

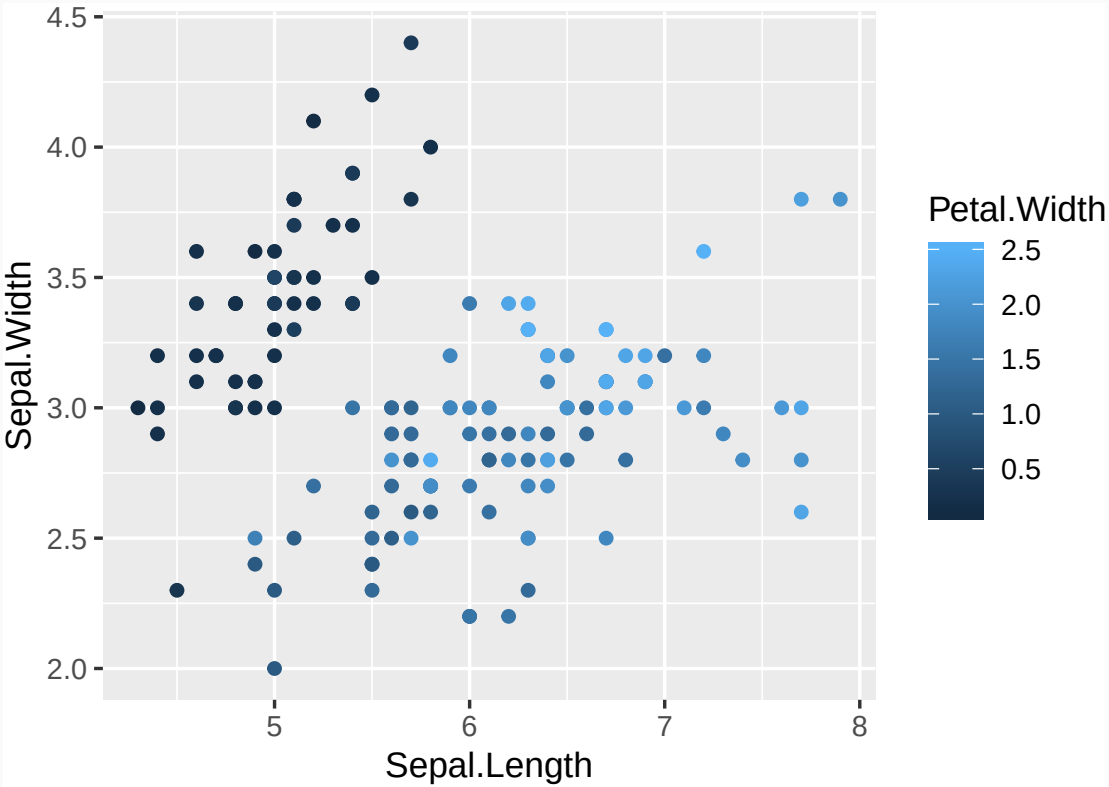

Changer la couleur

```
> ggplot(iris)+aes(x=Sepal.Length,y=Sepal.Width,
+                  color=Petal.Width)+geom_point()+
+            scale_color_continuous(low="yellow",high="red")
```

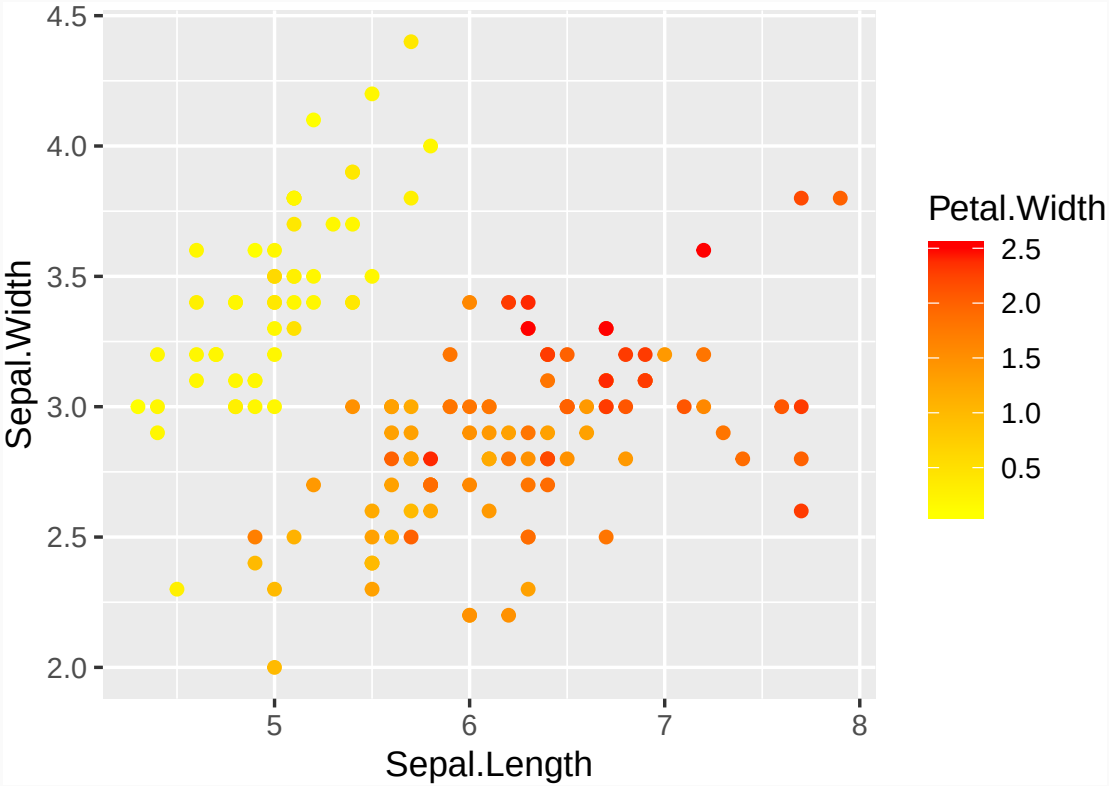

Histogramme

```
> ggplot(iris)+aes(x=Sepal.Length)+geom_histogram(fill="red")
```

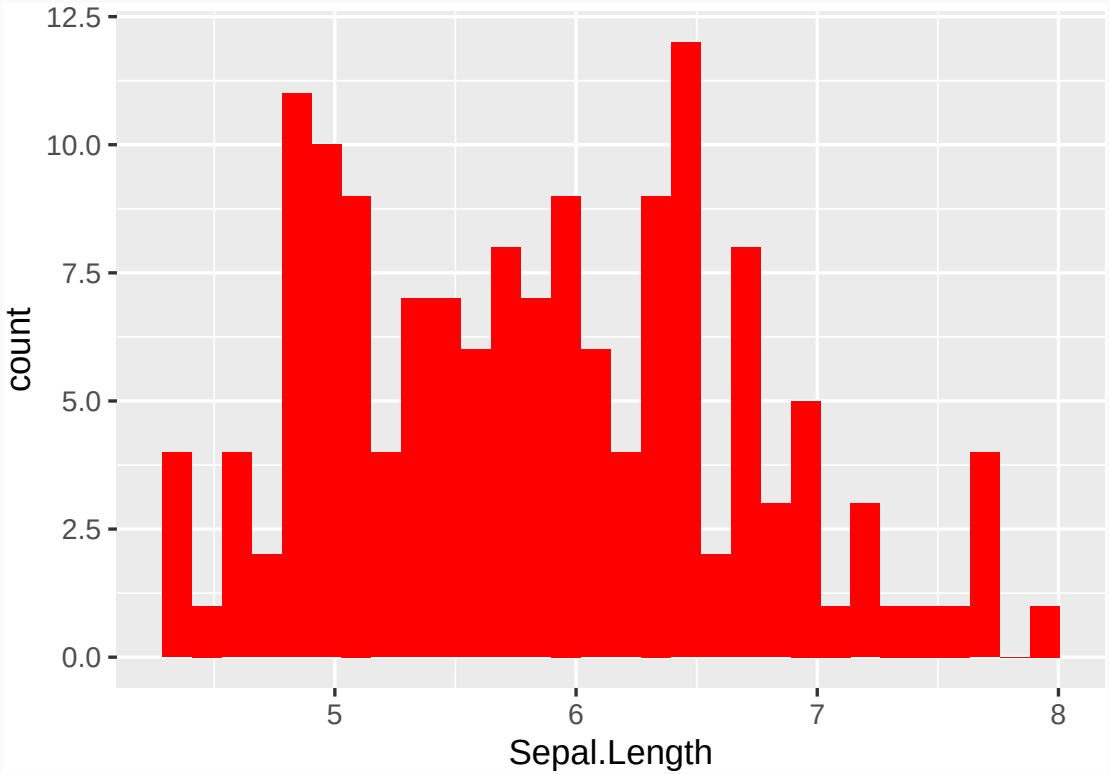

Diagramme en barres

```
> ggplot(iris)+aes(x=Species)+geom_bar(fill="blue")
```

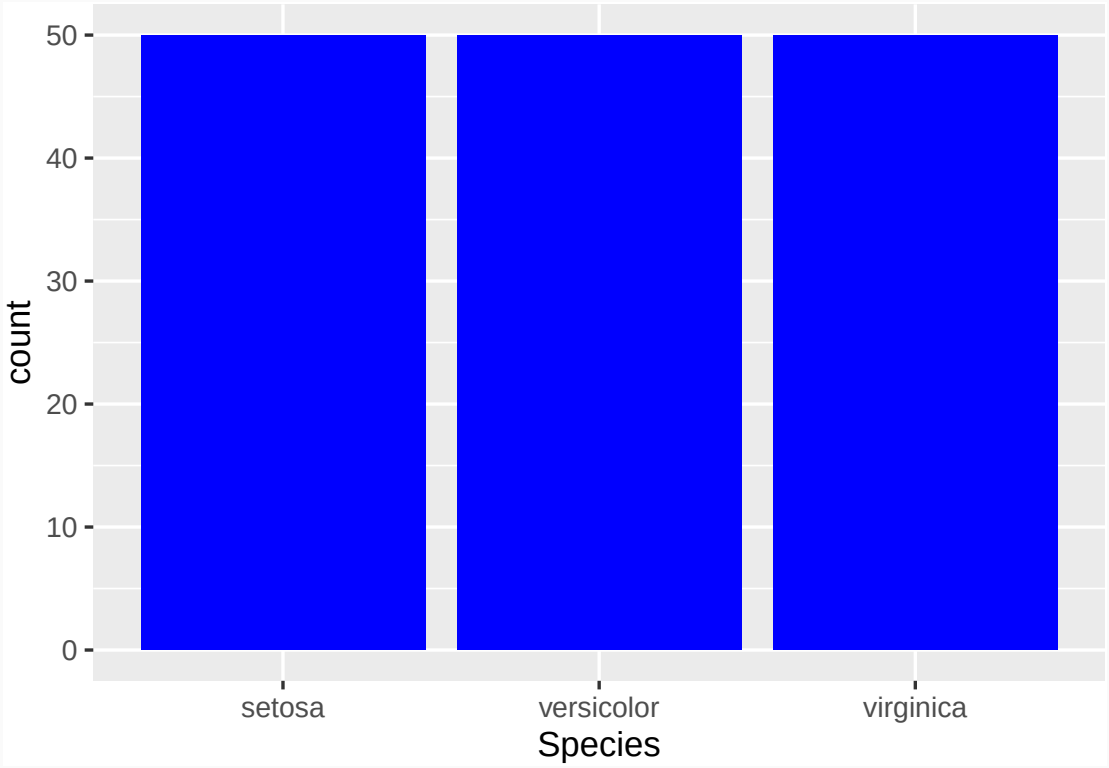

Facetting (plus compliqué)

```
> ggplot(iris)+aes(x=Sepal.Length,y=Sepal.Width)+geom_point()+
+       geom_smooth(method="lm")+facet_wrap(~Species)
```

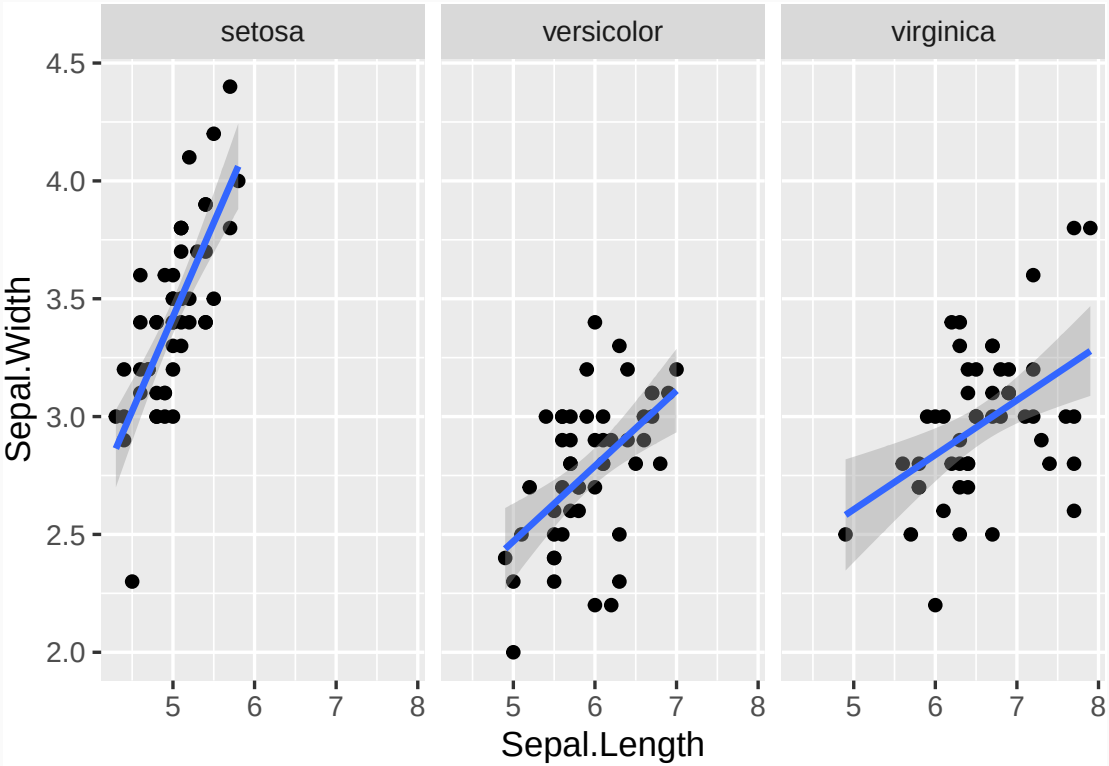

Combiner ggplot et dplyr

- Souvent important de construire un bon jeu de données pour obtenir un bon graphe.
- Par exemple

```
> head(df)
## # A tibble: 6 x 3
##    size weight.20 weight.50
##   <dbl>     <dbl>     <dbl>
## 1   153      61.2      81.4
## 2   169      67.5      81.4
## 3   168      69.4      80.3
## 4   169      66.1      81.9
## 5   176      70.4      79.2
## 6   169      67.6      88.9
```

Objectif

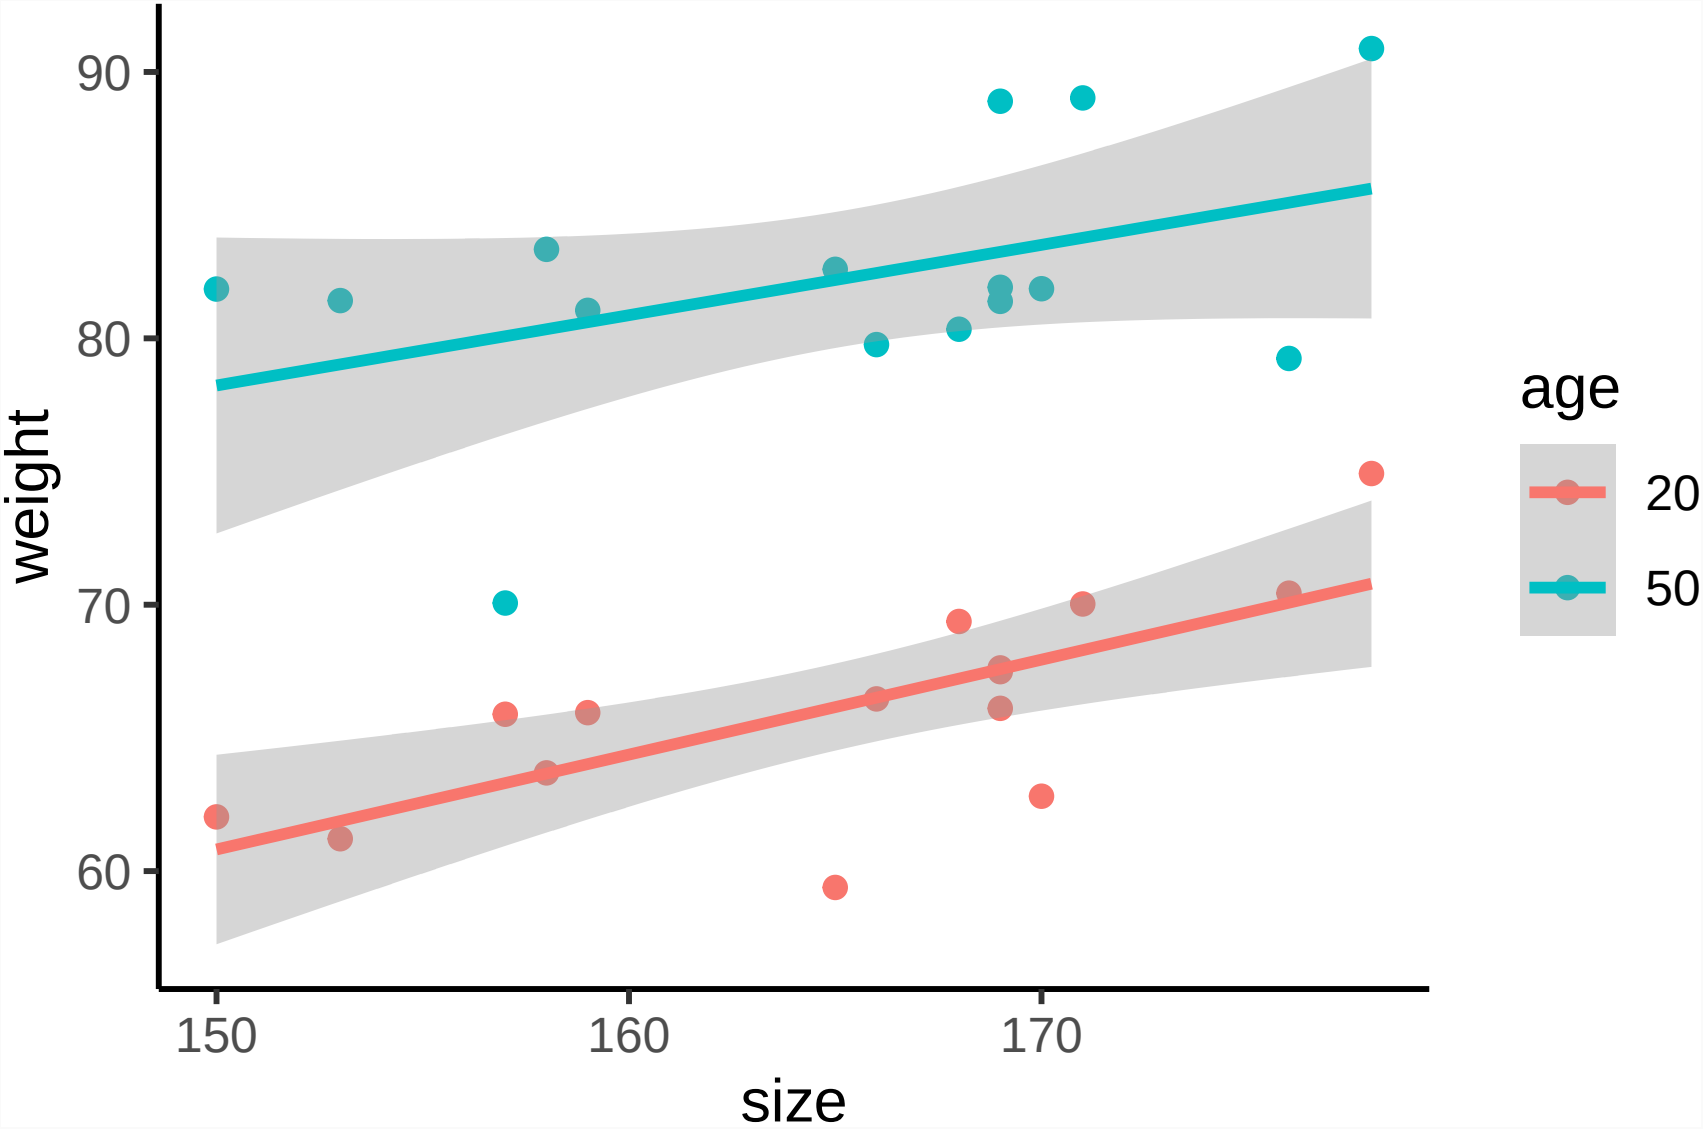

Etape dplyr

- Assembler les colonnes weight.M et weight.W en une colonne weight :

```
> df1 <- df %>% gather(key=age,value=weight,-size)
> df1 %>% head()
## # A tibble: 6 x 3
##    size age       weight
##   <dbl> <chr>      <dbl>
## 1   153 weight.20   61.2
## 2   169 weight.20   67.5
## 3   168 weight.20   69.4
## 4   169 weight.20   66.1
## 5   176 weight.20   70.4
## 6   169 weight.20   67.6
> df1 <- df1 %>% mutate(age=recode(age,
+    "weight.20"="20","weight.50"="50"))
```

Etape ggplot

```
> ggplot(df1)+aes(x=size,y=weight,color=age)+
+   geom_point()+geom_smooth(method="lm")+theme_classic()
```

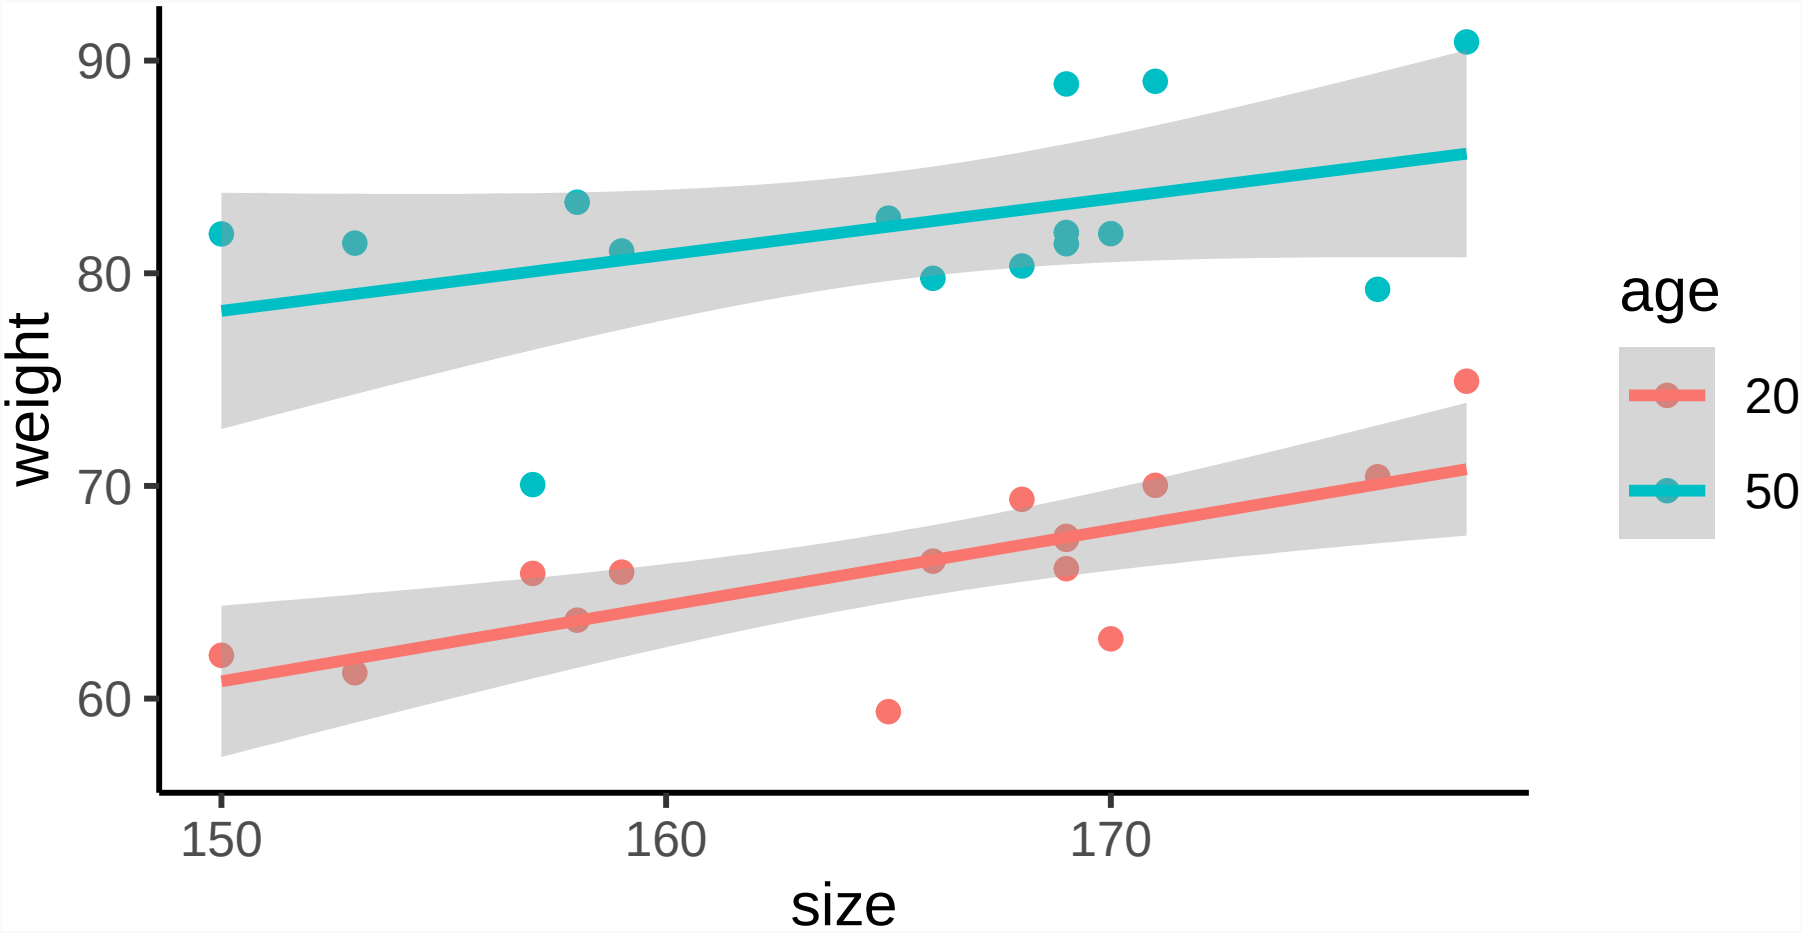

Compléments : quelques démos

```
> demo(image)
> example(contour)
> demo(persp)
> library("lattice");demo(lattice)
> example(wireframe)
> library("rgl");demo(rgl)
> example(persp3d)
> demo(plotmath);demo(Hershey)
```

Cartes

Introduction

- De nombreuses applications nécessitent des cartes pour visualiser des données ou les résultats d'un modèle.
- De nombreux packages R : ggmap, RgoogleMaps, maps...
- Dans cette partie : ggmap, sf et leaflet.

Fonds de carte ggmap

```
> library(ggmap)
> us <- c(left = -125, bottom = 25.75, right = -67, top = 49)
> map <- get_stamenmap(us, zoom = 5, maptype = "toner-lite")
> ggmap(map)
```

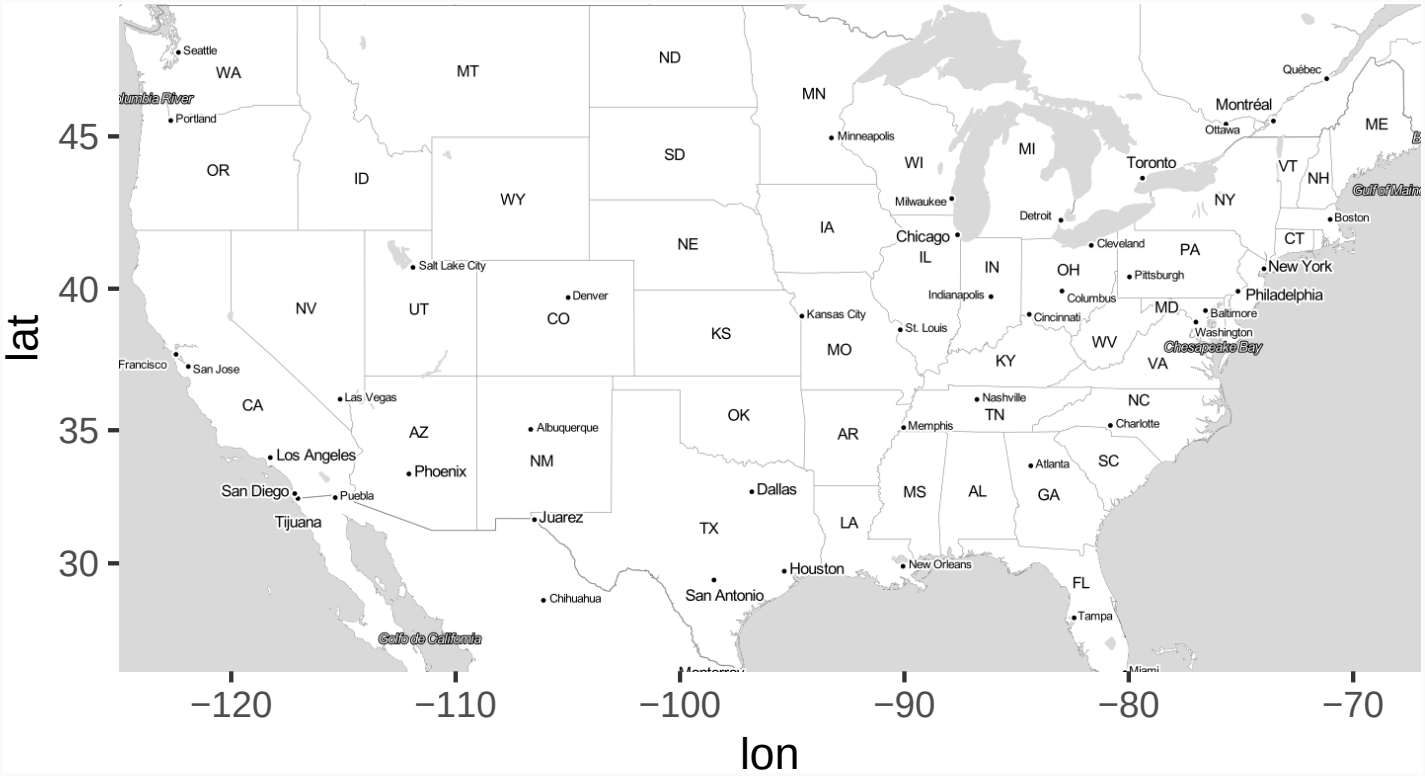

Ajouts avec ggplot

```
> fr <- c(left = -6, bottom = 41, right = 10, top = 52)
> fond <- get_stamenmap(fr, zoom = 5,"toner-lite")
> Paris <- data.frame(lon=2.351499,lat=48.85661)
> ggmap(fond)+geom_point(data=Paris,aes(x=lon,y=lat),color="red")
```

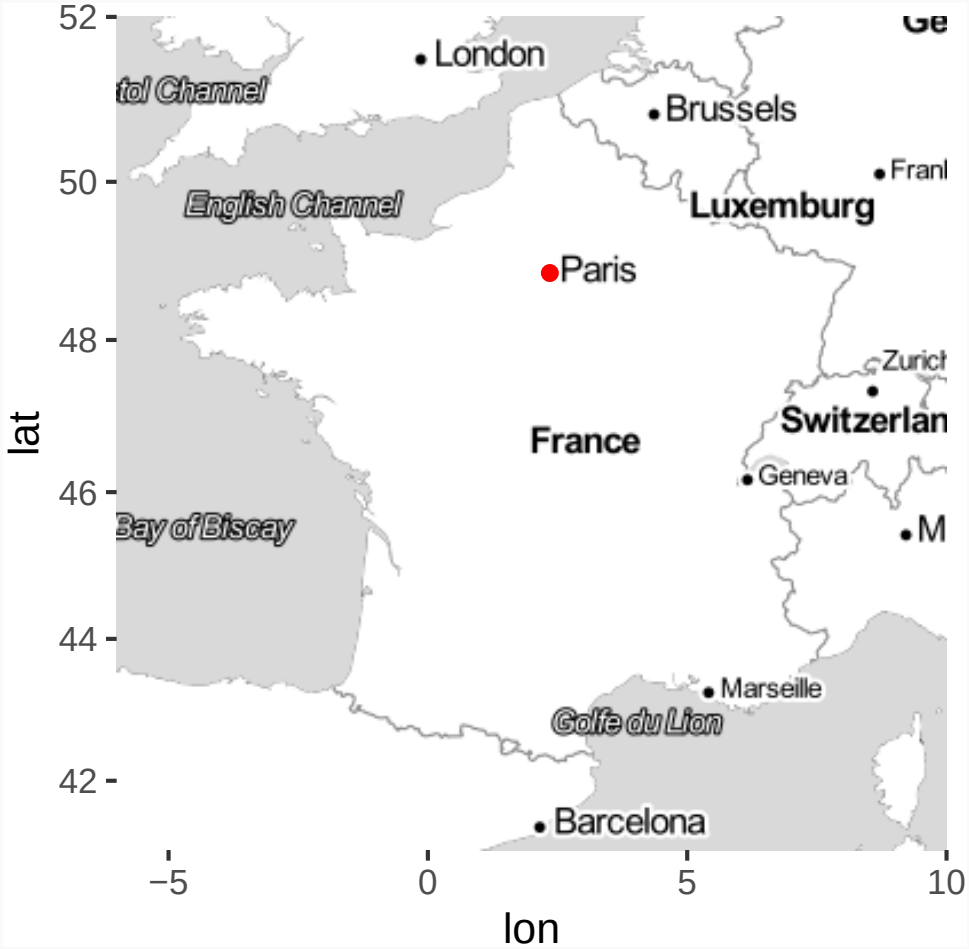

Fond de cartes avecfrontières

- On peut aussi représenter un fond de carte avec des longitudes et latitudes de frontières.

```
> library(maps)
> france <- map(database="france",plot=FALSE)
> fr1 <- tibble(lon=france$x,lat=france$y)
> head(fr1)
## # A tibble: 6 x 2
##     lon   lat
##   <dbl> <dbl>
## 1  2.56  51.1
## 2  2.58  51.0
## 3  2.61  51.0
## 4  2.63  51.0
## 5  2.63  50.9
## 6  2.60  50.9
```

```
> ggplot(fr1)+geom_path(aes(y=lat,x=lon),size=1)+theme_void()
```

Le package sf

- Permet de gérer des objets spécifiques à la cartographie : notamment les différents systèmes de coordonnées et leurs projections en 2d.
- Exemple : colorier des régions (définies par des polygones).
- Compatible avec ggplot.

Références

- https://statnmap.com/fr/2018-07-14-initiation-a-la-cartographie-avec-sf-et-compagnie/
- Vignettes sur le cran : https://cran.r-project.org/web/packages/sf/index.html.

Exemple

```
> library(sf)
> dpt <- read_sf("dpt")
> dpt[1:5,3]
## Simple feature collection with 5 features and 1 field
## geometry type:  MULTIPOLYGON
## dimension:      XY
## bbox:           xmin: 644570 ymin: 6290136 xmax: 1022851 ymax: 6997000
## epsg (SRID):    2154
## proj4string:    +proj=lcc +lat_1=49 +lat_2=44 +lat_0=46.5 +lon_0=3 +x_0=7
## # A tibble: 5 x 2
##   NOM_DEPT                                                          g
##   <chr>                                                    <MULTIPOLYG
## 1 AIN                  (((919195 6541470, 918932 6541203, 918628 6540523, 9
## 2 AISNE                (((735603 6861428, 735234 6861392, 734504 6861270, 7
## 3 ALLIER               (((753769 6537043, 753554 6537318, 752879 6538099, 7
## 4 ALPES-DE-HAUTE-PR~ (((992638 6305621, 992263 6305688, 991610 6306540, 9
## 5 HAUTES-ALPES         (((1012913 6402904, 1012577 6402759, 1010853 640293
```

```
> plot(st_geometry(dpt))
```

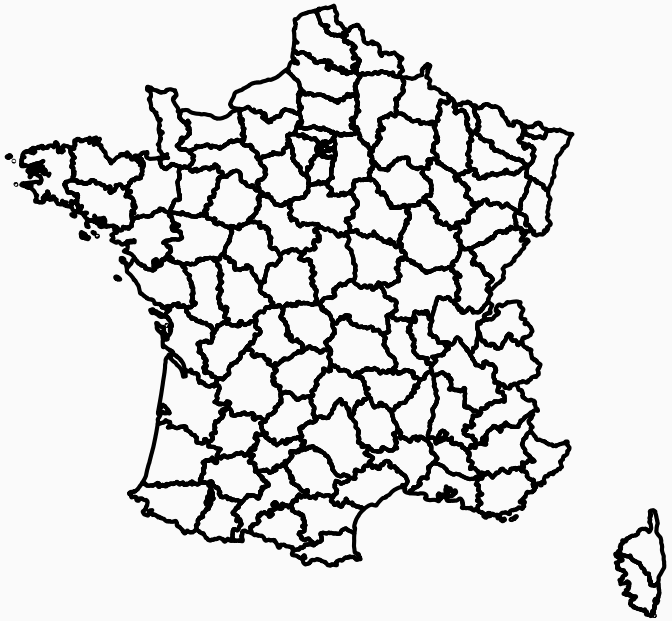

```
> ggplot(dpt)+geom_sf()
```

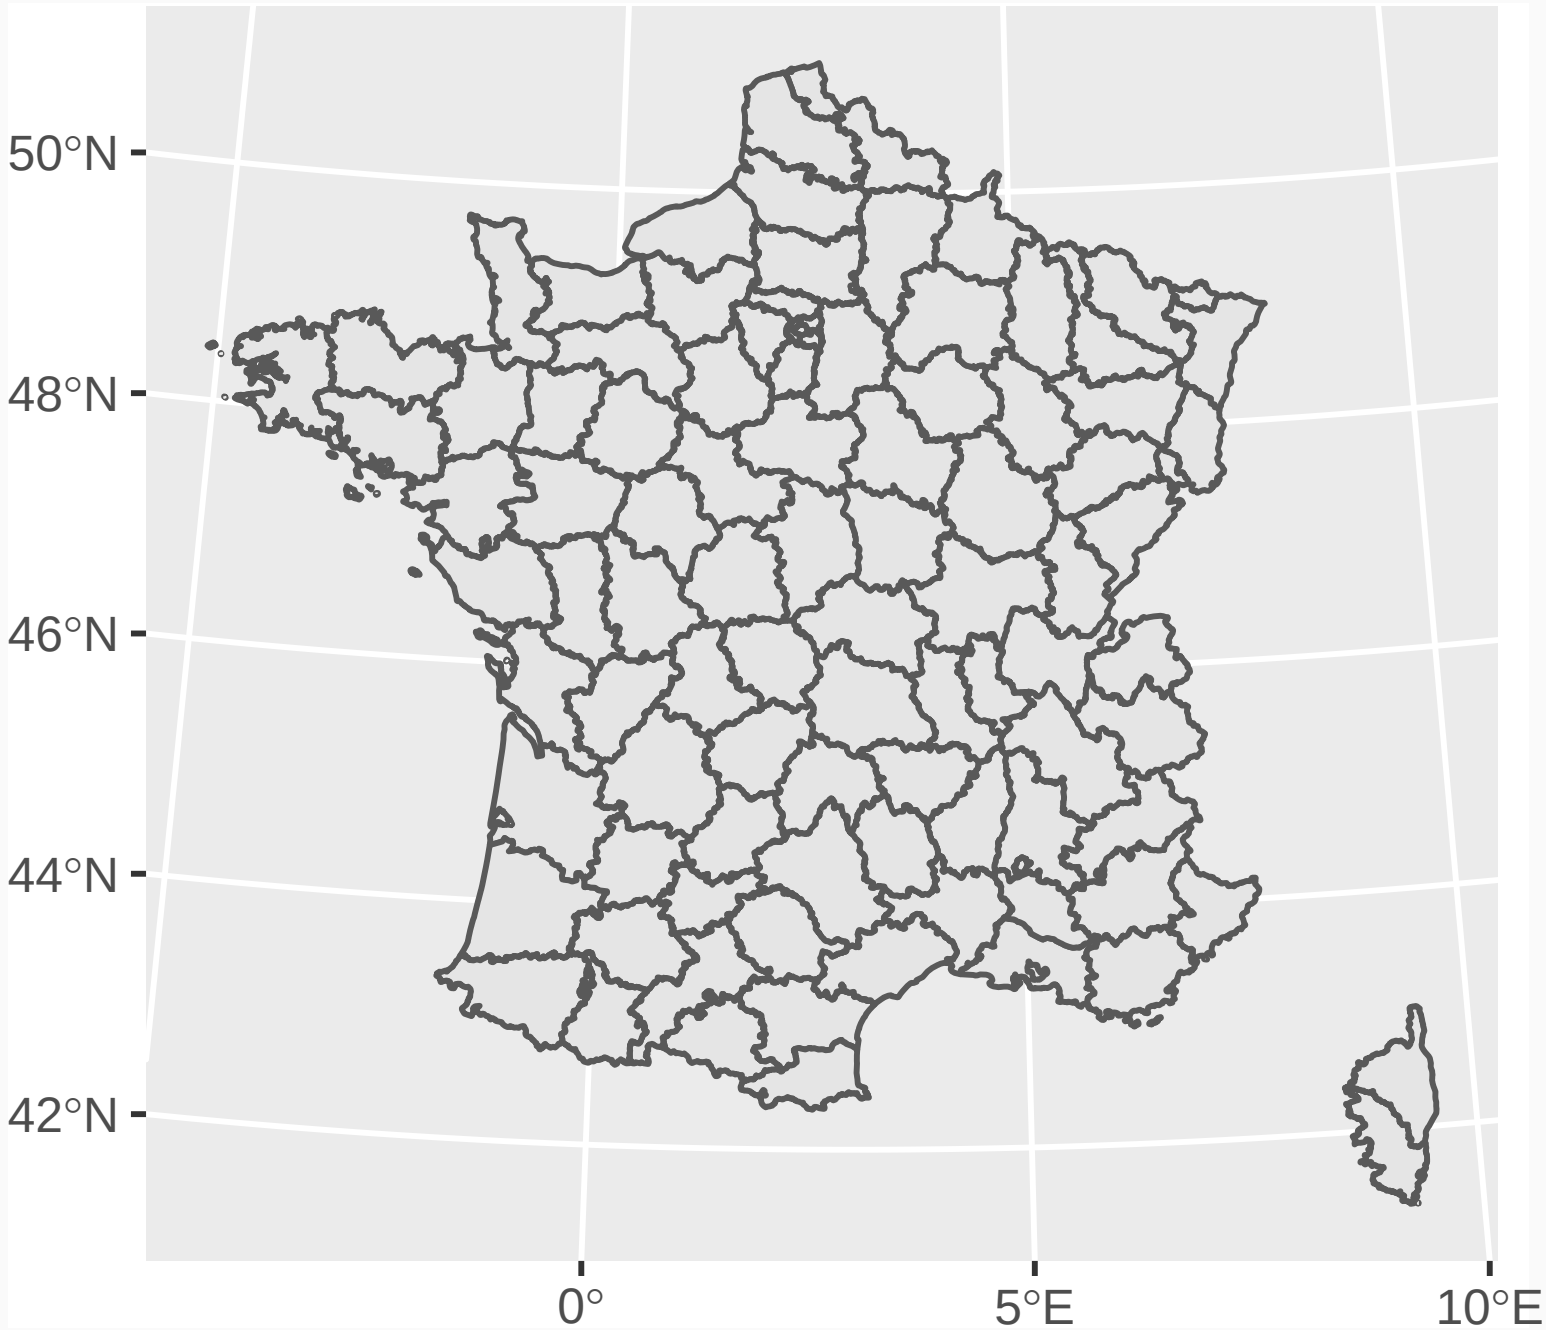

Ajouter des points sur le graphe

```
> point <- st_sfc(st_point(c(2.351462,48.85670)),
+                 st_point(c(4.832011,45.75781)),
+                 st_point(c(5.369953,43.29617)))
> st_crs(point) <- 4326 #coord sont des long/lat
> point
## Geometry set for 3 features
## geometry type:  POINT
## dimension:      XY
## bbox:           xmin: 2.351462 ymin: 43.29617 xmax: 5.369953 ymax: 48.856
## epsg (SRID):    4326
## proj4string:    +proj=longlat +datum=WGS84 +no_defs
```

```
> ggplot(dpt) + geom_sf(fill="white")+
+   geom_sf(data=point,color="red",size=4)+theme_void()
```

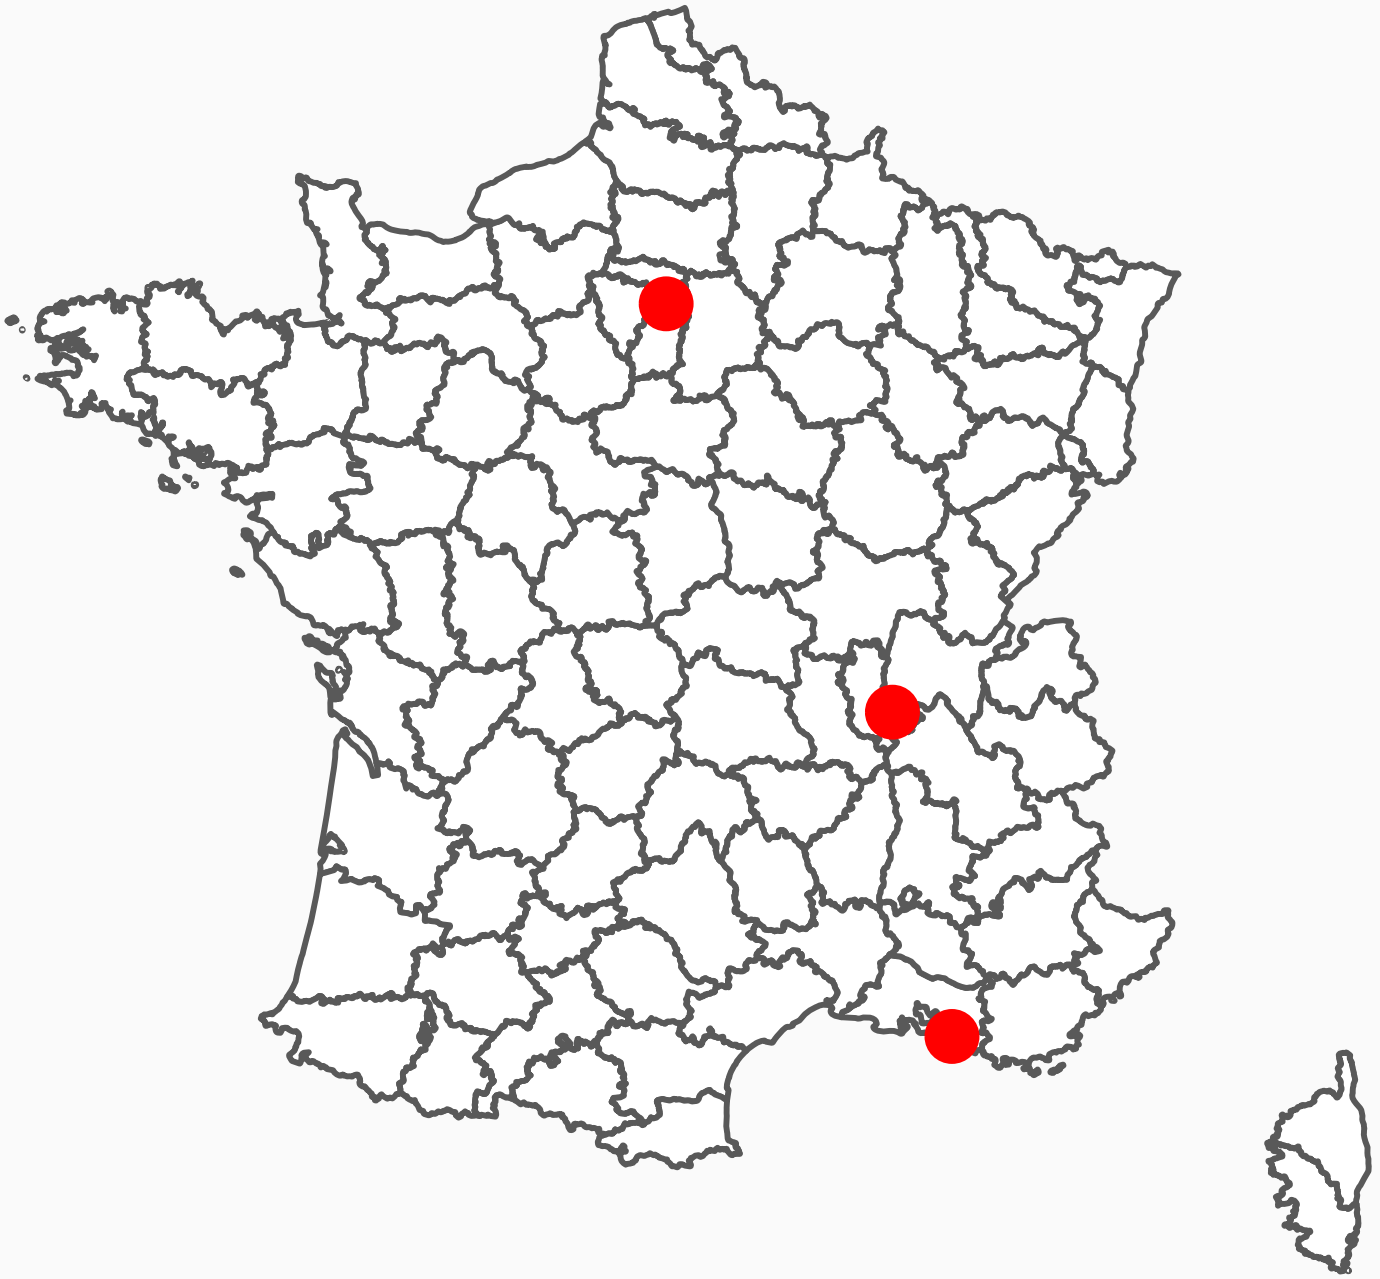

Colorier des polygones

```
> set.seed(1234)
> dpt1 <- dpt %>% mutate(temp=runif(96,10,20))
> ggplot(dpt1) + geom_sf(aes(fill=temp)) +
+   scale_fill_continuous(low="yellow",high="red")+
+   theme_void()
```

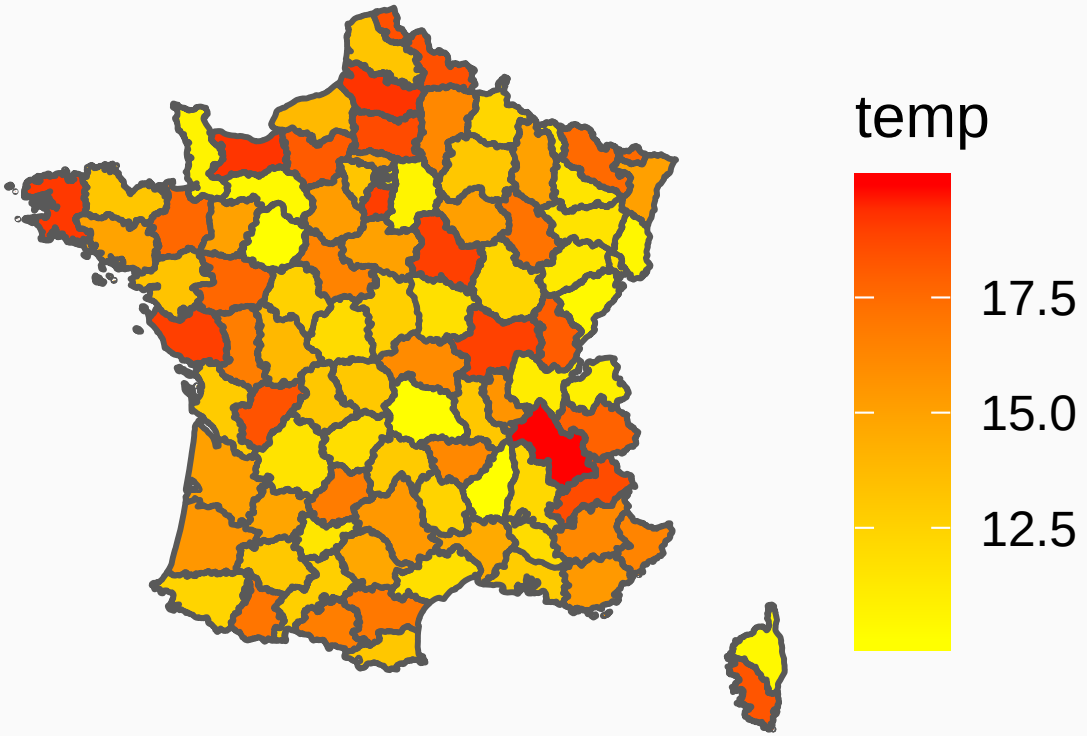

Fonds de carte

- Leaflet est une des librairies open-source JavaScript les plus populaires pour faire des cartes interactives.
- Documentation: here

```
> library(leaflet)
> leaflet() %>% addTiles()
```

Différents styles de fonds de carte

```
> Paris <- c(2.35222,48.856614)
> leaflet() %>% addTiles() %>%
+   setView(lng = Paris[1], lat = Paris[2],zoom=12)
```

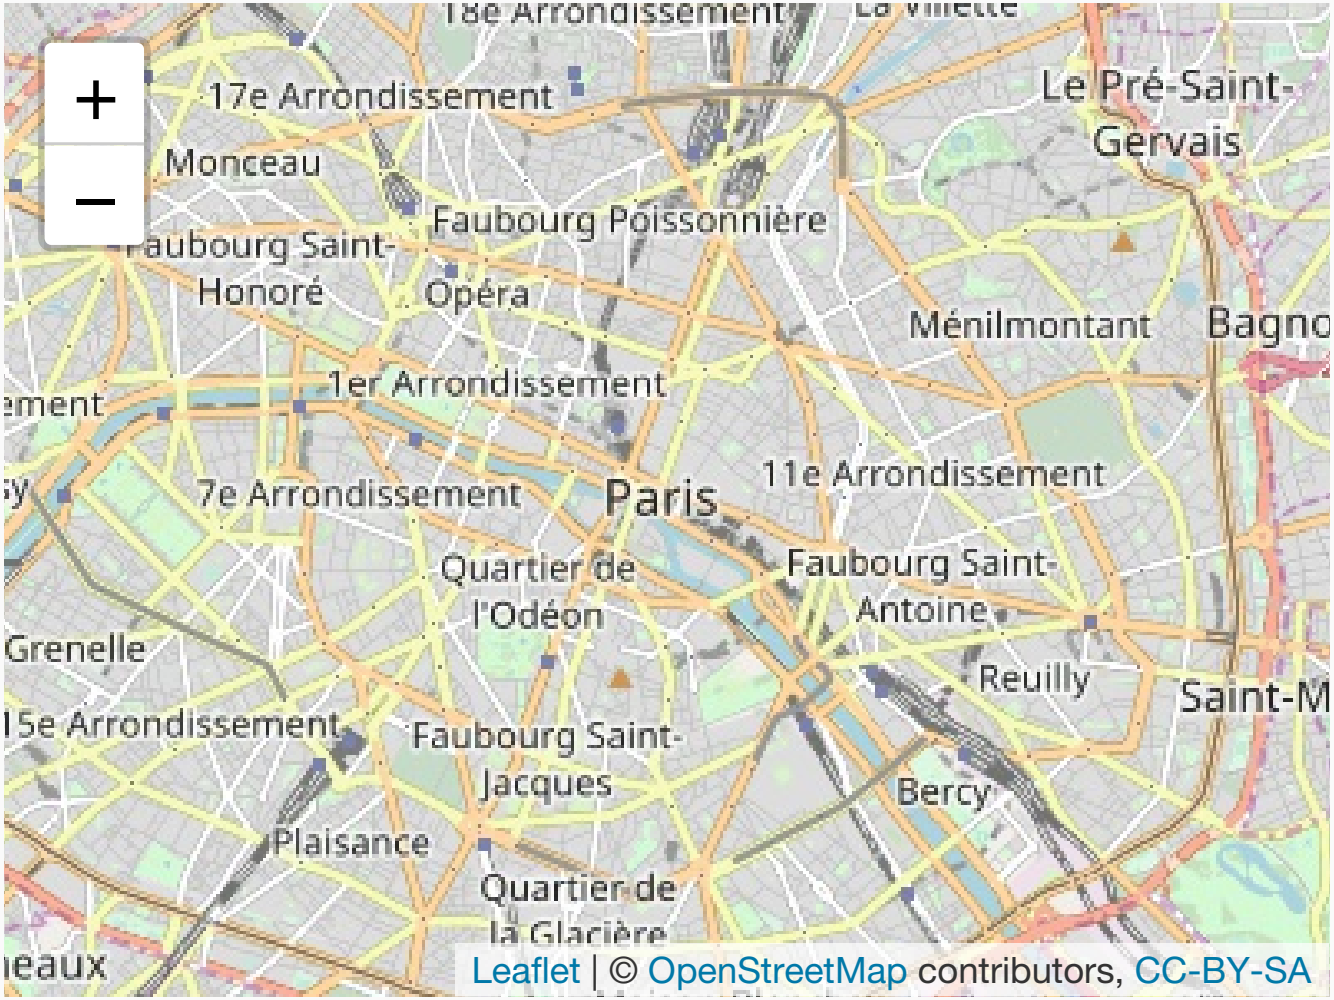

```
> leaflet() %>% addProviderTiles("Stamen.Toner") %>%
+   setView(lng = Paris[1], lat = Paris[2], zoom = 12)
```

Avec des données

- Localiser 1000 séismes près des Fiji

```
> data(quakes)
> head(quakes)
##      lat   long depth mag stations
## 1 -20.42 181.62   562 4.8       41
## 2 -20.62 181.03   650 4.2       15
## 3 -26.00 184.10    42 5.4       43
## 4 -17.97 181.66   626 4.1       19
## 5 -20.42 181.96   649 4.0       11
## 6 -19.68 184.31   195 4.0       12
```

Séismes avec une magnitude plus grande que 5.5

```
> quakes1 <- quakes %>% filter(mag>5.5)
> leaflet(data = quakes1) %>% addTiles() %>%
+   addMarkers(~long, ~lat, popup = ~as.character(mag))
```

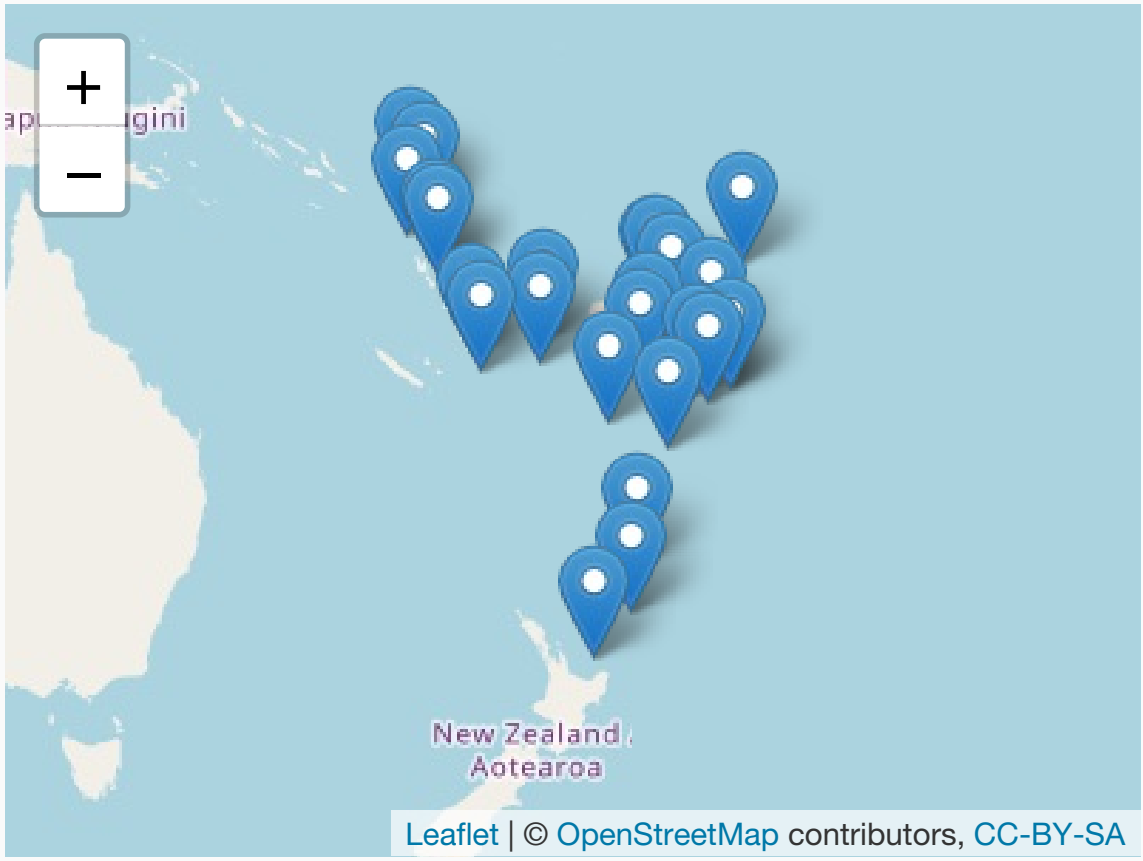

Remarque

La magnitude apparaît lorsqu'on clique sur un marker.

addCircleMarkers

```
> leaflet(data = quakes1) %>% addTiles() %>%
+   addCircleMarkers(~long, ~lat, popup=~as.character(mag),
+                    radius=3,fillOpacity = 0.8,color="red")
```