Visualisation avec R

Laurent Rouvière

Janvier 2020

Présentation

- Prérequis : niveau avancé en **R** - bases en statistique et programmation
- Objectifs :
  - Comprendre l'importance de la visualisation en science des données
  - visualiser des données, des modèles et des résultats
  - découvrir quelques packages de visualisation en R
- Ressources:
  - slides et notebook R

Complément

Workshop Shiny en février.

Pourquoi un cours de visualisation ?

- Données de plus en plus complexes
- Modèles de plus en plus complexes
- Interprétations des résultats de plus en plus complexes.

Pourquoi un cours de visualisation ?

- Données de plus en plus complexes
- Modèles de plus en plus complexes
- Interprétations des résultats de plus en plus complexes.

Conséquence

La visualisation se révèle cruciale tout au long d'une étude statistique.

Pourquoi un cours de visualisation ?

- Données de plus en plus complexes
- Modèles de plus en plus complexes
- Interprétations des résultats de plus en plus complexes.

Conséquence

La visualisation se révèle cruciale tout au long d'une étude statistique.

- Besoin de visualiser pour :
  - décrire les données
  - calibrer les modèles
  - présenter les résultats de l'étude.

Plan

- (au moins) 2 façons d'appréhender la visualisation :
  1. Méthodes/modèles statistiques: PCA, LDA, arbres...
  2. Outils: packages R.

Plan

- (au moins) 2 façons d'appréhender la visualisation :
  1. Méthodes/modèles statistiques: PCA, LDA, arbres...
  2. Outils: packages R.

- Dans ce cours, on va présenter quelques outils R :
  1. ggplot2 : un package R pourv visuasliser les données (3-4h).
  2. Cartes avec ggmap, sf et leaflet (3-4h).
  3. Visualisation intéractive avec rAmCharts, leaflet et shiny (3-4h).

Plan

- (au moins) 2 façons d'appréhender la visualisation :
  1. Méthodes/modèles statistiques: PCA, LDA, arbres...
  2. Outils: packages R.

- Dans ce cours, on va présenter quelques outils R :
  1. ggplot2 : un package R pourv visuasliser les données (3-4h).
  2. Cartes avec ggmap, sf et leaflet (3-4h).
  3. Visualisation intéractive avec rAmCharts, leaflet et shiny (3-4h).

Remarque

De plus en plus de packages R sont dédiés à la visualisation.

Introduction

ggplot2

```
> library(tidyverse) #ggplot2 dans tidyverse
> ggplot(iris)+aes(x=Species,y=Sepal.Length)+geom_boxplot()
```

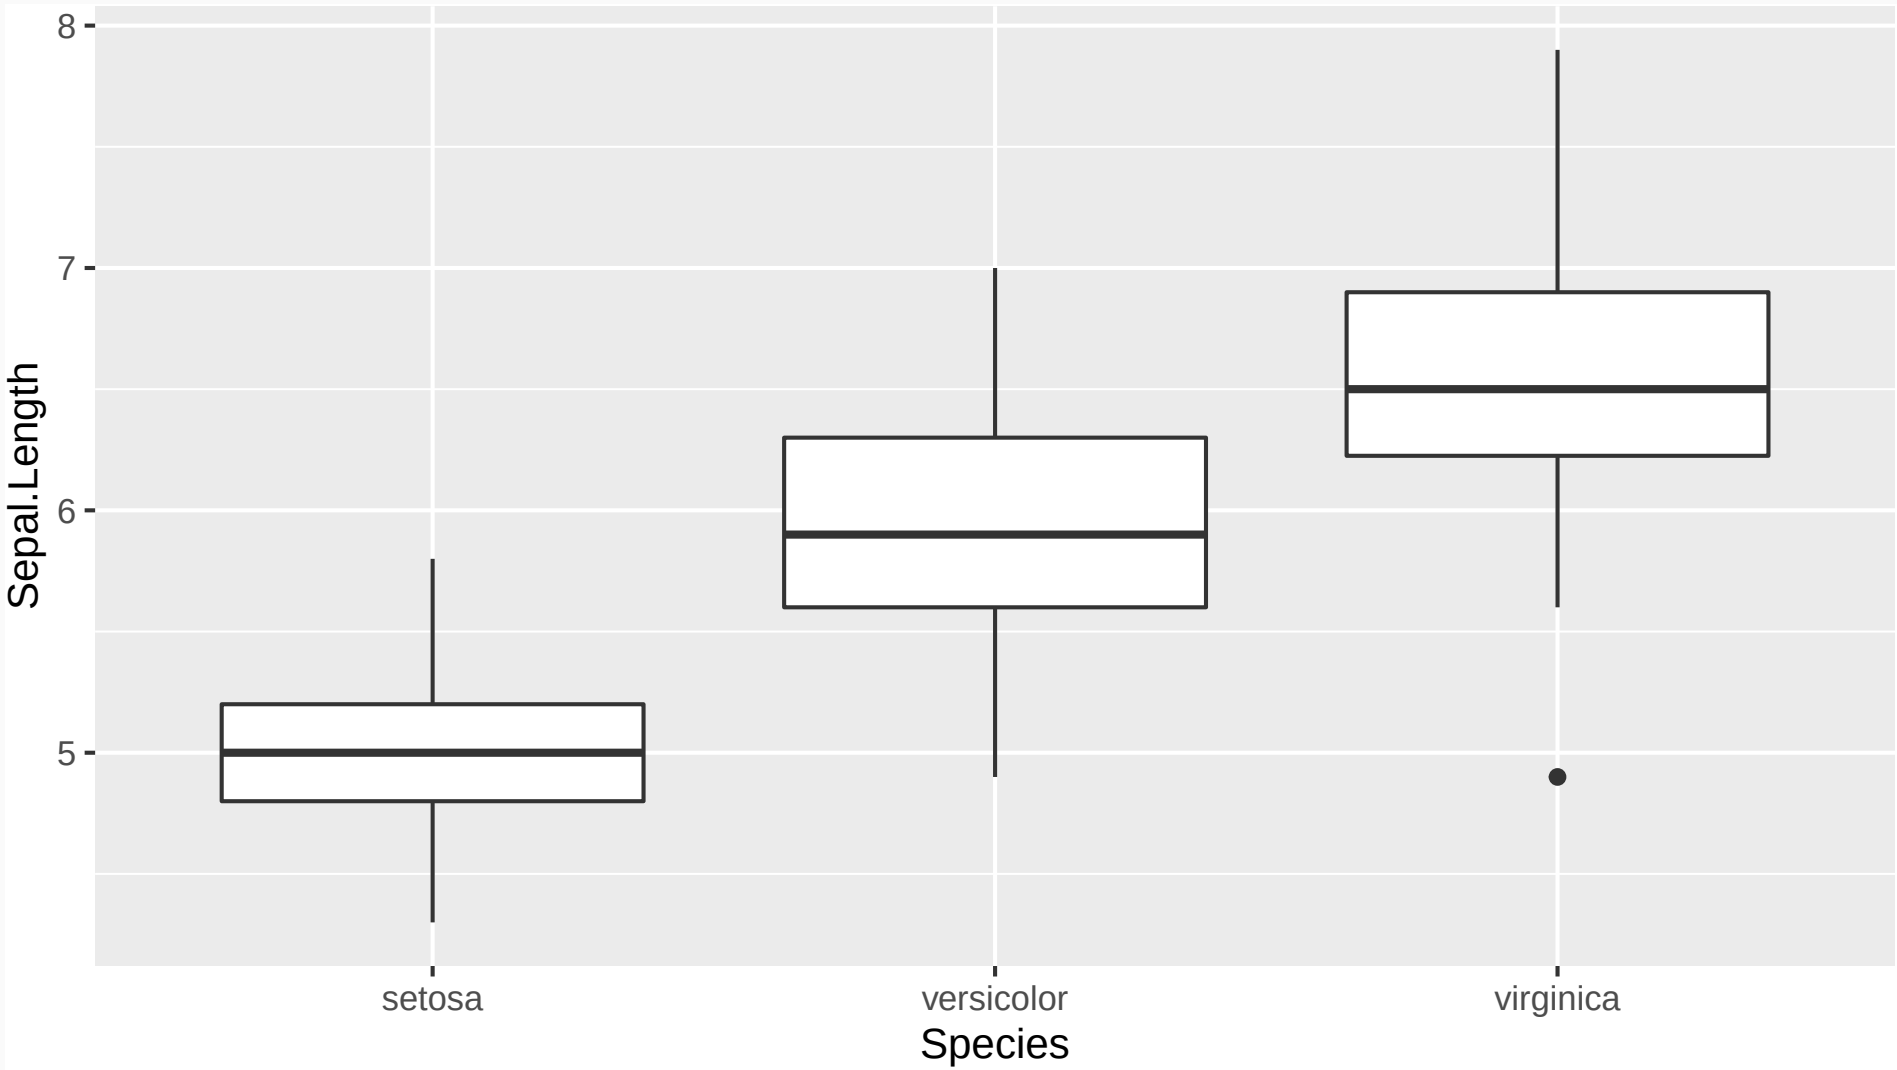

Une carte de températures avec ggmap

```
> library(ggmap)
> ggmap(fond)+geom_polygon(data=Test5,
+   aes(y=Latitude,x=Longitude,fill=temp1,color=temp1,
+       group=dept),size=1)+
+   scale_fill_continuous(low="yellow",high="red")+
+   scale_color_continuous(low="yellow",high="red")
```

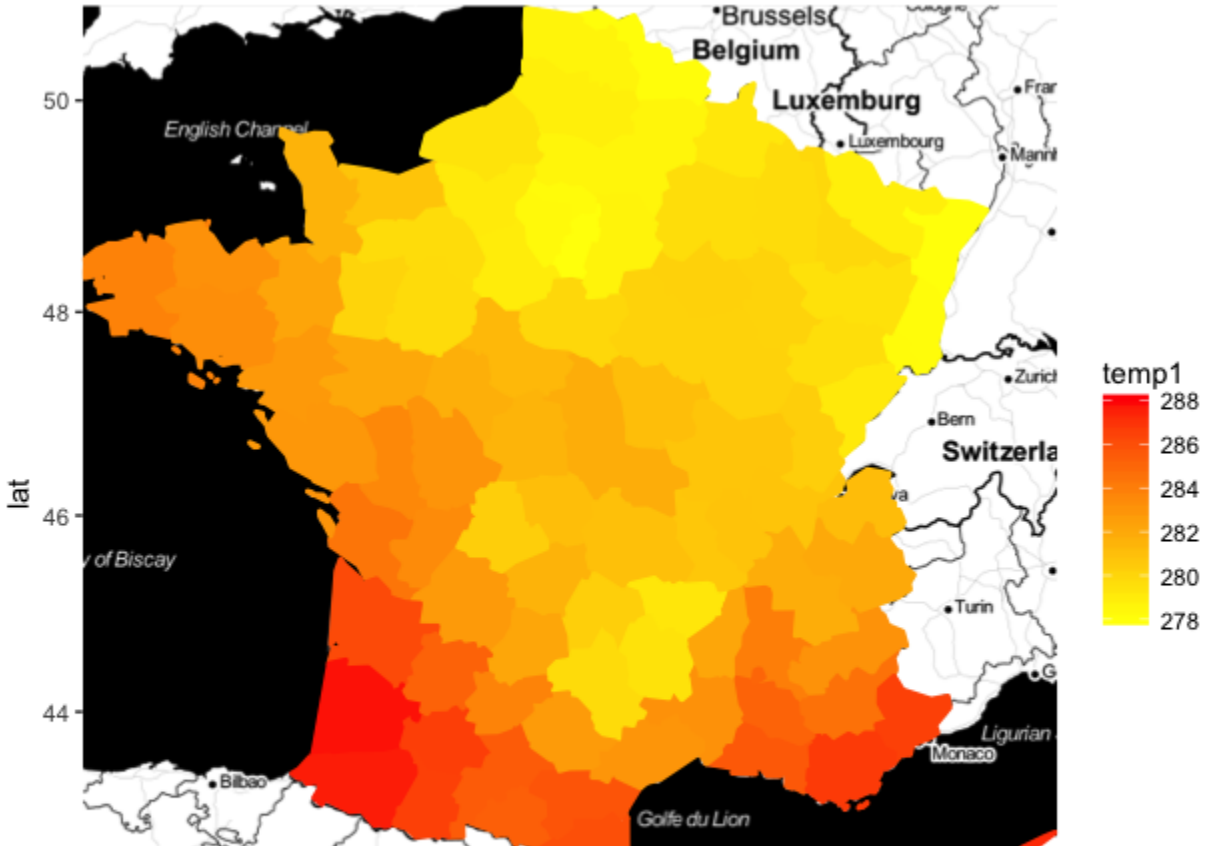

Visu intéractive avec rAmCharts

```
> library(rAmCharts)
> amBoxplot(Sepal.Length~Species,data=iris)
```

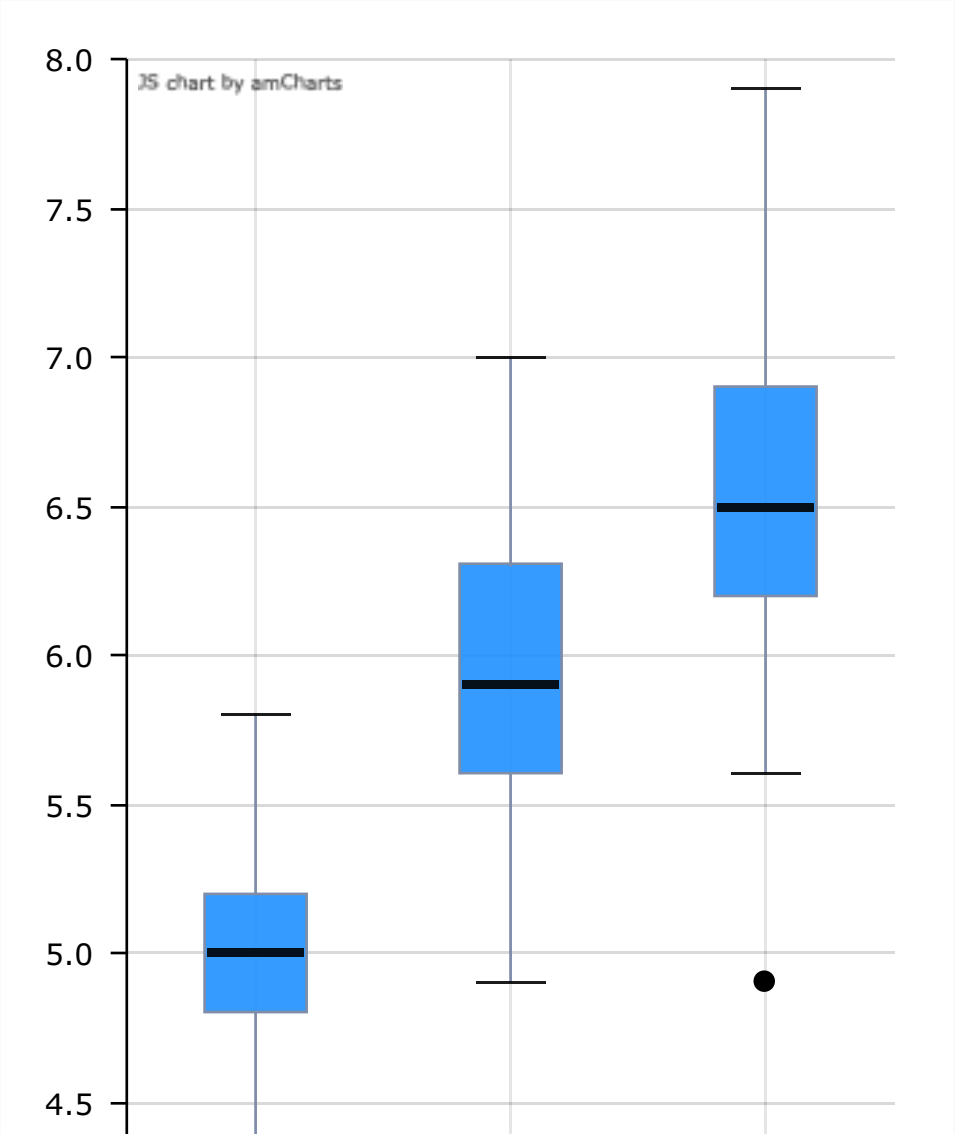

Applications web intéractives avec shiny

- Shiny est un package R qui permete de faire “facilement” des applications web intéractives.

- Example: stations velib à Rennes
  https://data.rennesmetropole.fr/page/home/

```
> library(shiny)
> runApp('desc_app.R')
> runApp('app_velib.R')
> runApp('trace_roc_app.R')
```

Visualisation avec ggplot2

La fonction plot (rappels)

- Fonction générique pour représenter (presque) tous les types de données.
- Pour un nuage de points, il suffit de renseigner un vecteur pour l'axe des x, et un autre vecteur pour celui des y.

```
> x <- seq(-2*pi,2*pi,by=0.1)
> plot(x,sin(x),type="l",xlab="x",ylab="sin(x)")
> abline(h=c(-1,1))
```

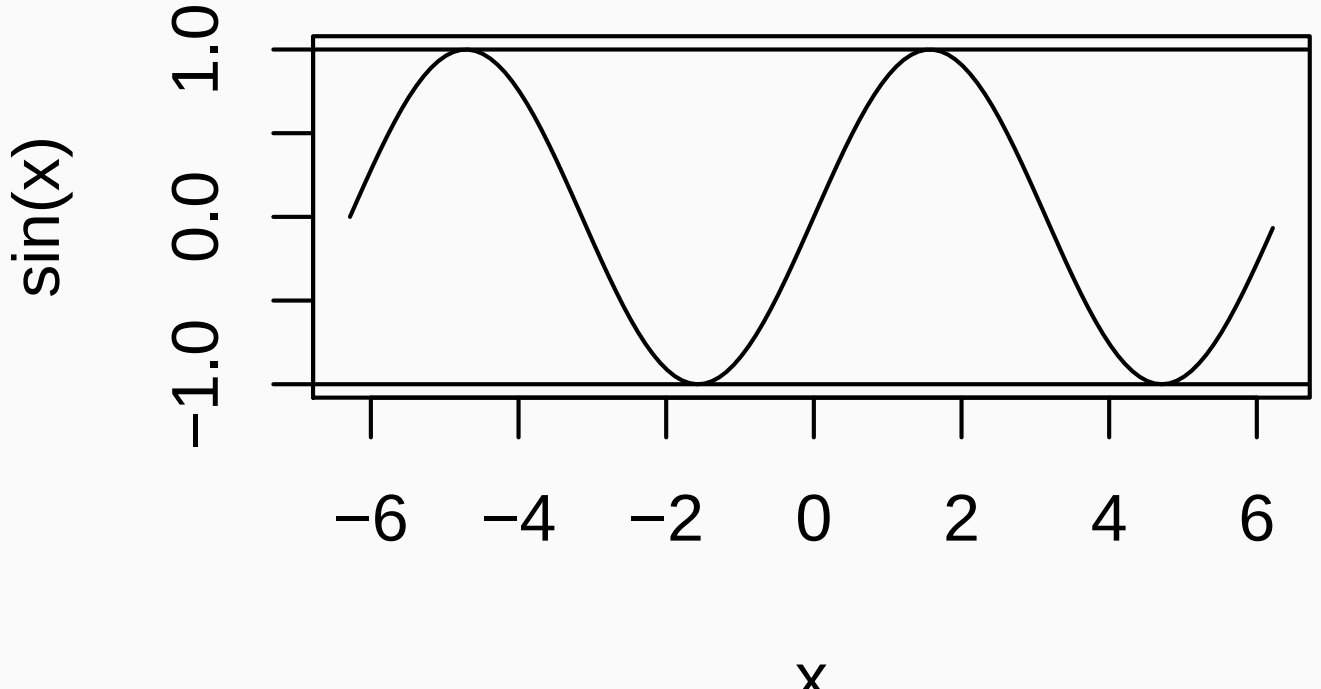

Graphes classiques pour visualiser des variables

- Histogramme pour une variable continue, diagramme en barres pour une variable qualitative.
- Nuage de points pour 2 variables continues.
- Boxplot pour une distribution continue.

Graphes classiques pour visualiser des variables

- Histogramme pour une variable continue, diagramme en barres pour une variable qualitative.
- Nuage de points pour 2 variables continues.
- Boxplot pour une distribution continue.

Constat (positif)

Il existe une fonction R pour toutes les représentations.

Nuage de points sur un jeu de données

```
> plot(Sepal.Length~Sepal.Width,data=iris)
```

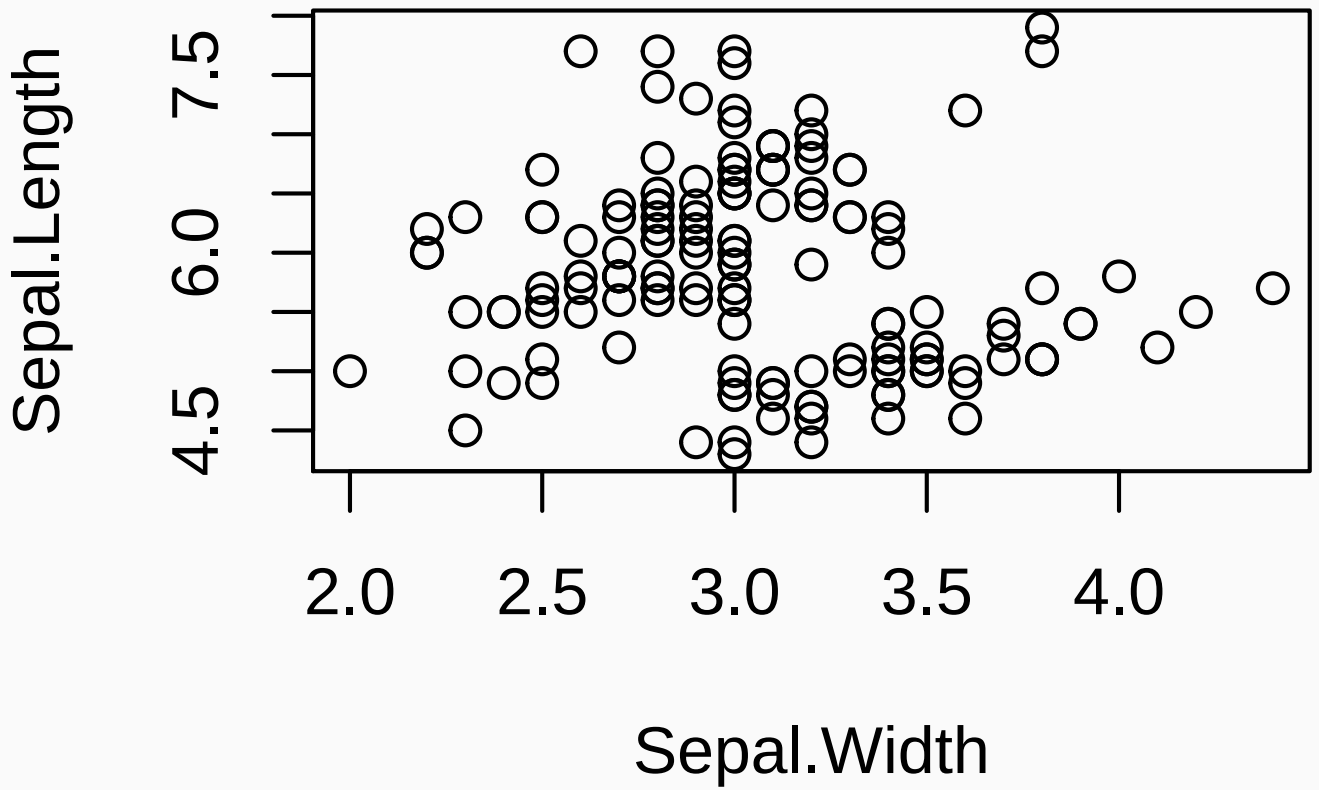


```
> #same as
> plot(iris$Sepal.Width,iris$Sepal.Length)
```

Histogramme (variable continue)

```
> hist(iris$Sepal.Length,col="red")
```

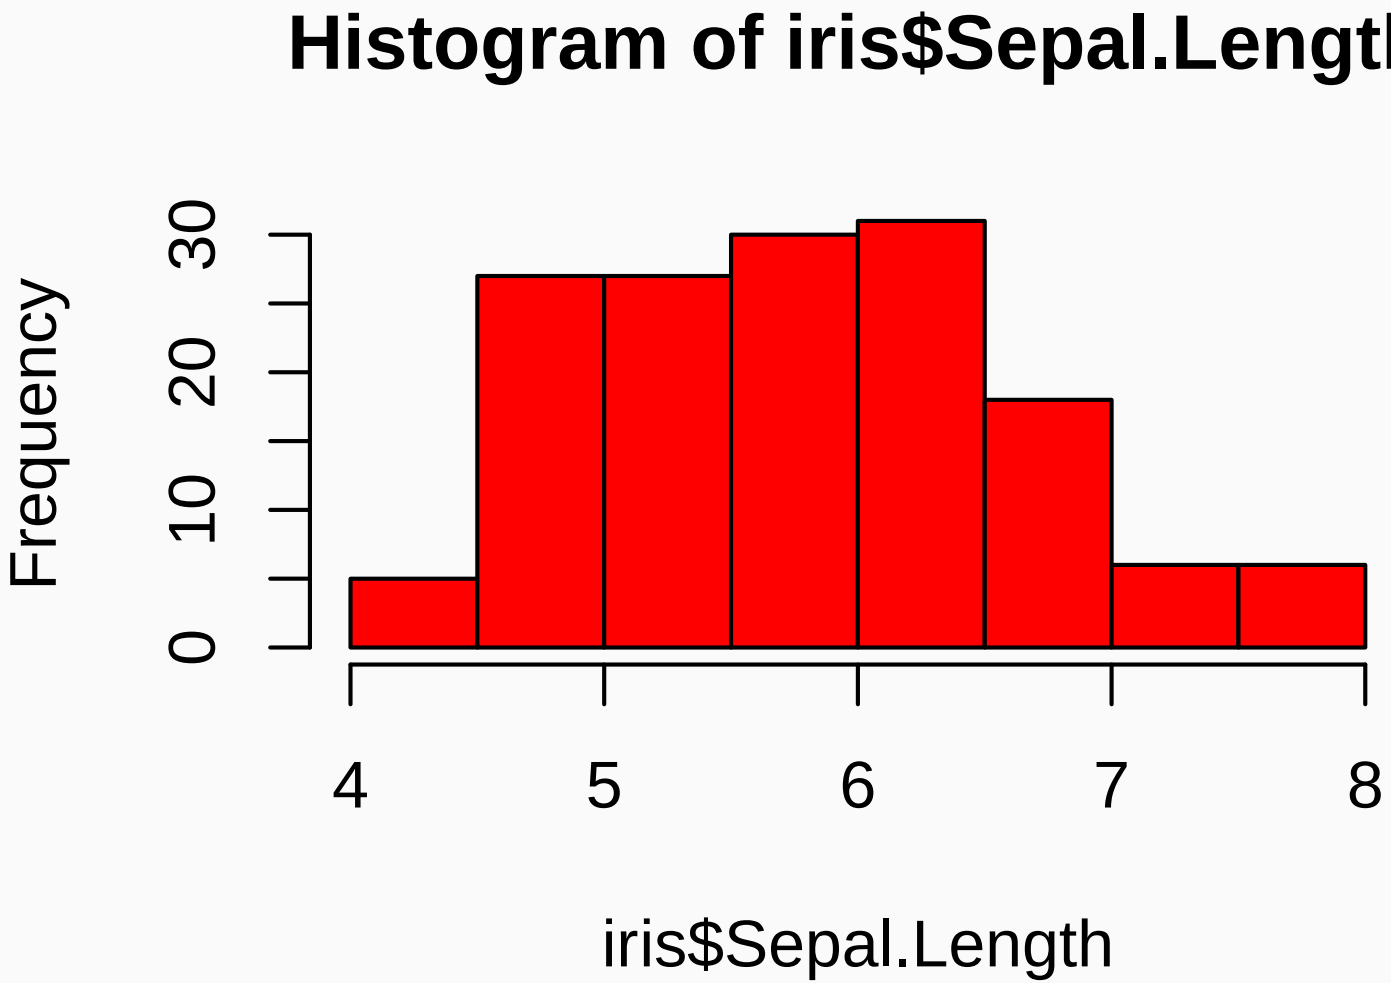

Diagramme en barres (variable qualitative)

```
> barplot(table(iris$Species))
```

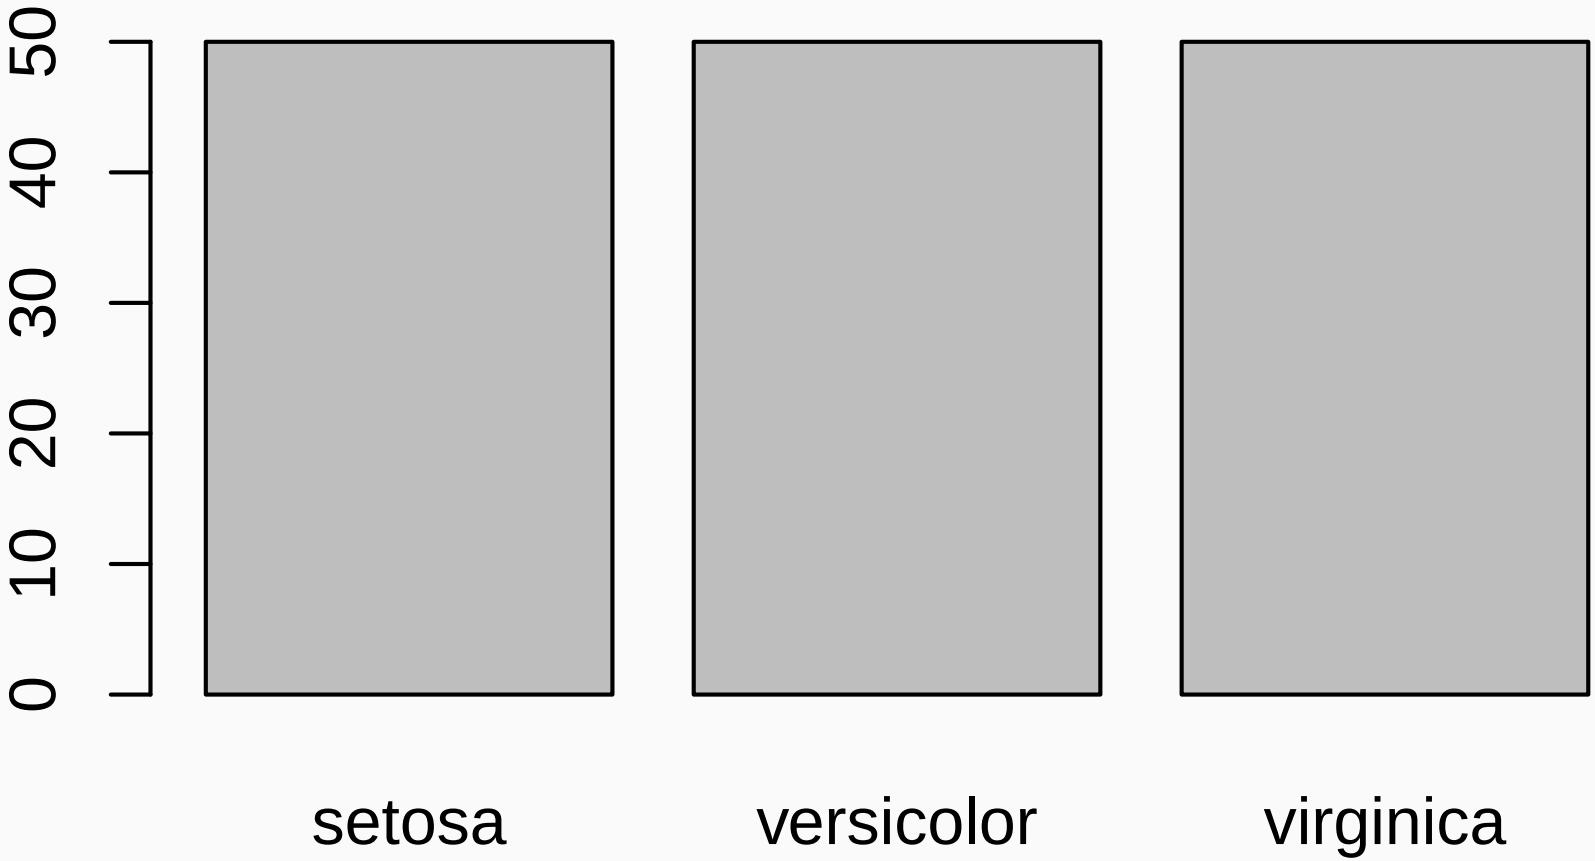

Boxplot (distribution)

```
> boxplot(Sepal.Length~Species,data=iris)
```

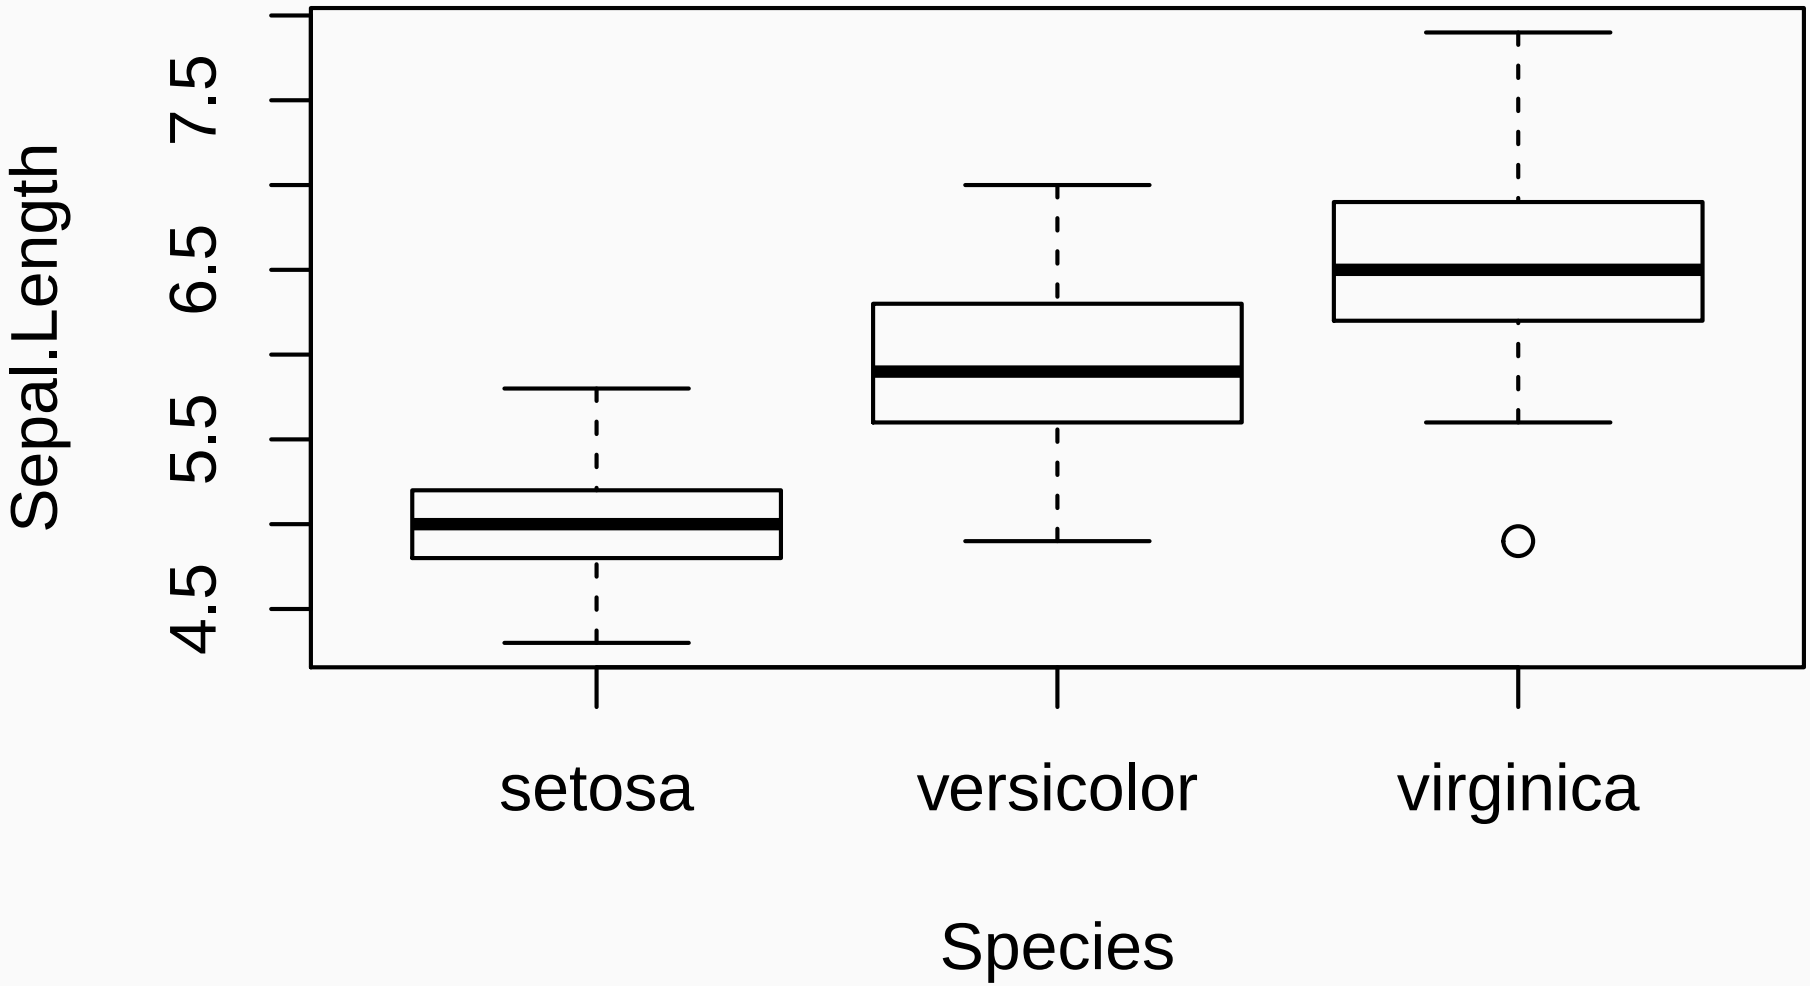

- ggplot2 permet de faire des graphes R en s'appuyant sur une grammaire des graphiques (équivalent de **dplyr** pour manipuler les données).
- Les graphes produits sont agréables à regarder (pas toujours le cas avec les graphes conventionnels).
- La grammaire ggplot permet d'obtenir des graphes "complexes" avec une syntaxe claire et lisible.

Pour un tableau de données fixé, un graphe est défini comme une succession de **couches**. Il faut toujours spécifier :

- les données
- les variables à représenter
- le type de représentation (nuage de points, boxplot...).

Pour un tableau de données fixé, un graphe est défini comme une succession de **couches**. Il faut toujours spécifier :

- les données
- les variables à représenter
- le type de représentation (nuage de points, boxplot...).

Les graphes ggplot sont construits à partir de ces couches. On indique

- les données avec **ggplot**
- les variables avec **aes** (aesthetics)
- le type de représentation avec **geom_**

La grammaire

Les principaux verbes sont

- **Data (ggplot)** : les données, un dataframe ou un tibble.
- **Aesthetics (aes)** : façon dont les variables doivent être représentées.
- **Geometrics (geom_...)** : type de représentation.
- **Statistics (stat_...)** : spécifier les transformations des données.
- **Scales (scale_...)** : modifier certains paramètres du graphe (changer de couleurs, de taille...).

Tous ces éléments sont séparés par un $+$.

Un exemple

```
> ggplot(iris)+aes(x=Sepal.Length,y=Sepal.Width)+geom_point()
```

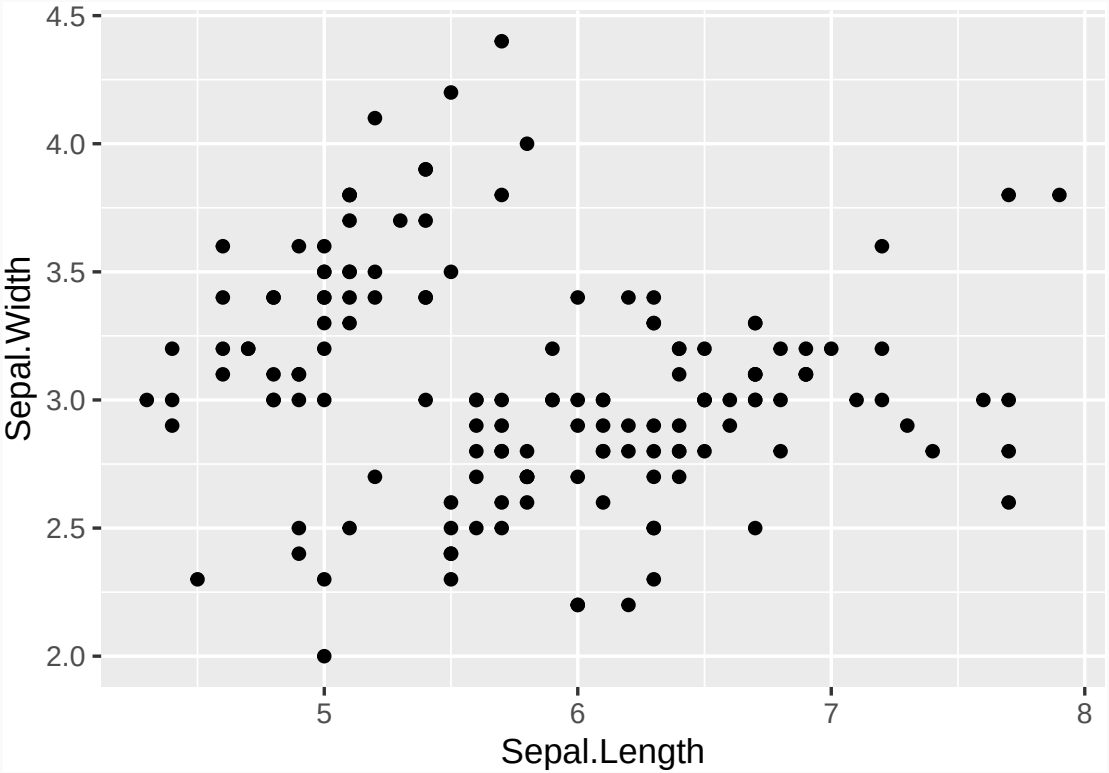

Couleur et taille

```
> ggplot(iris)+aes(x=Sepal.Length,y=Sepal.Width)+
+   geom_point(color="blue",size=2)
```

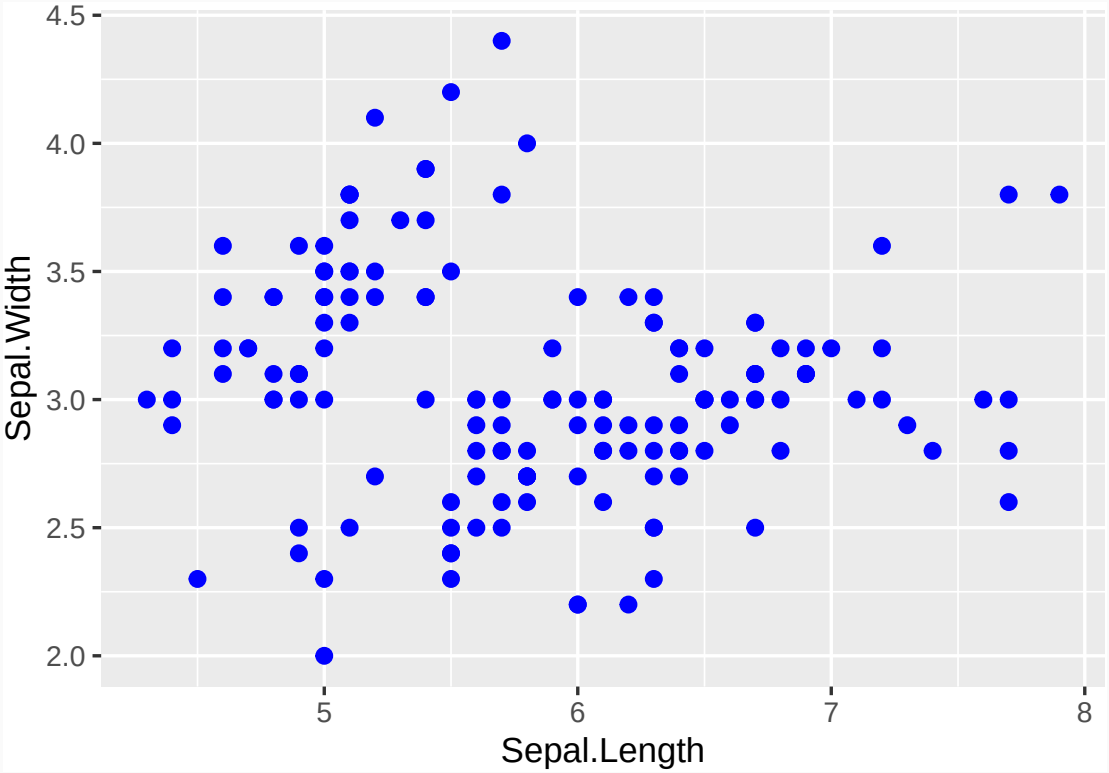

Couleur avec une variable qualitative

```
> ggplot(iris)+aes(x=Sepal.Length,y=Sepal.Width,
+                  color=Species)+geom_point()
```

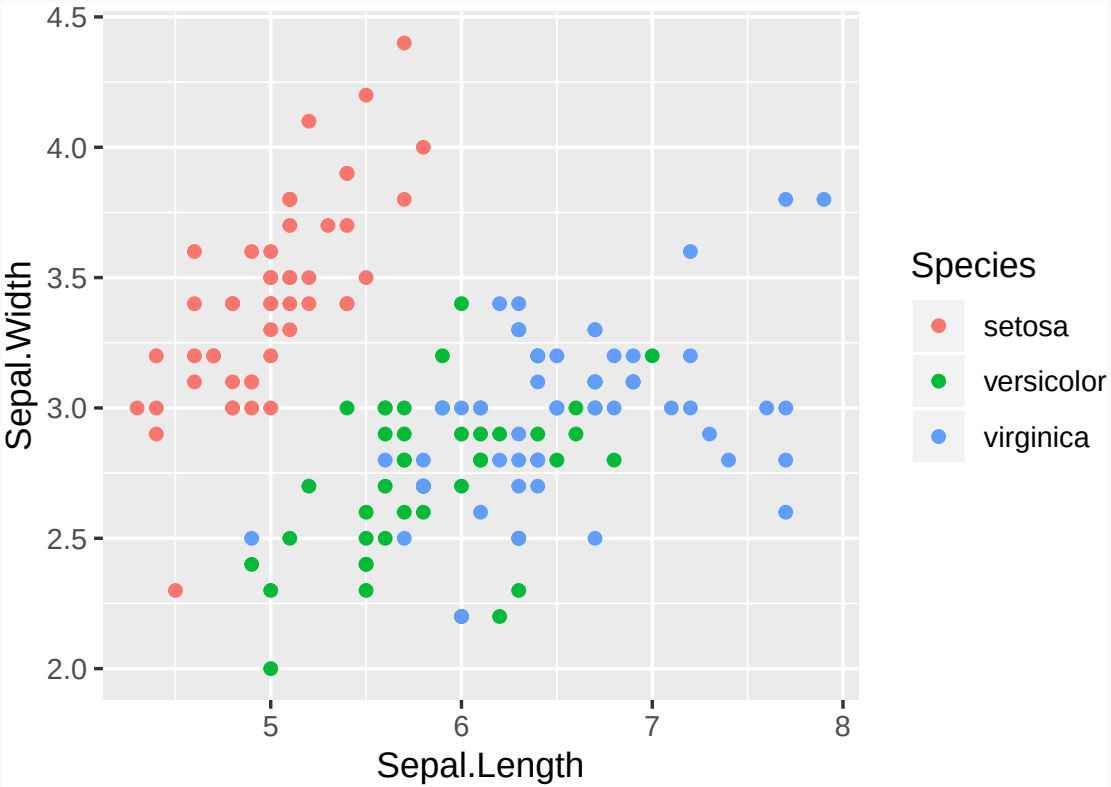

Couleur avec une variable continue

```
> ggplot(iris)+aes(x=Sepal.Length,y=Sepal.Width,
+                  color=Petal.Width)+geom_point()
```

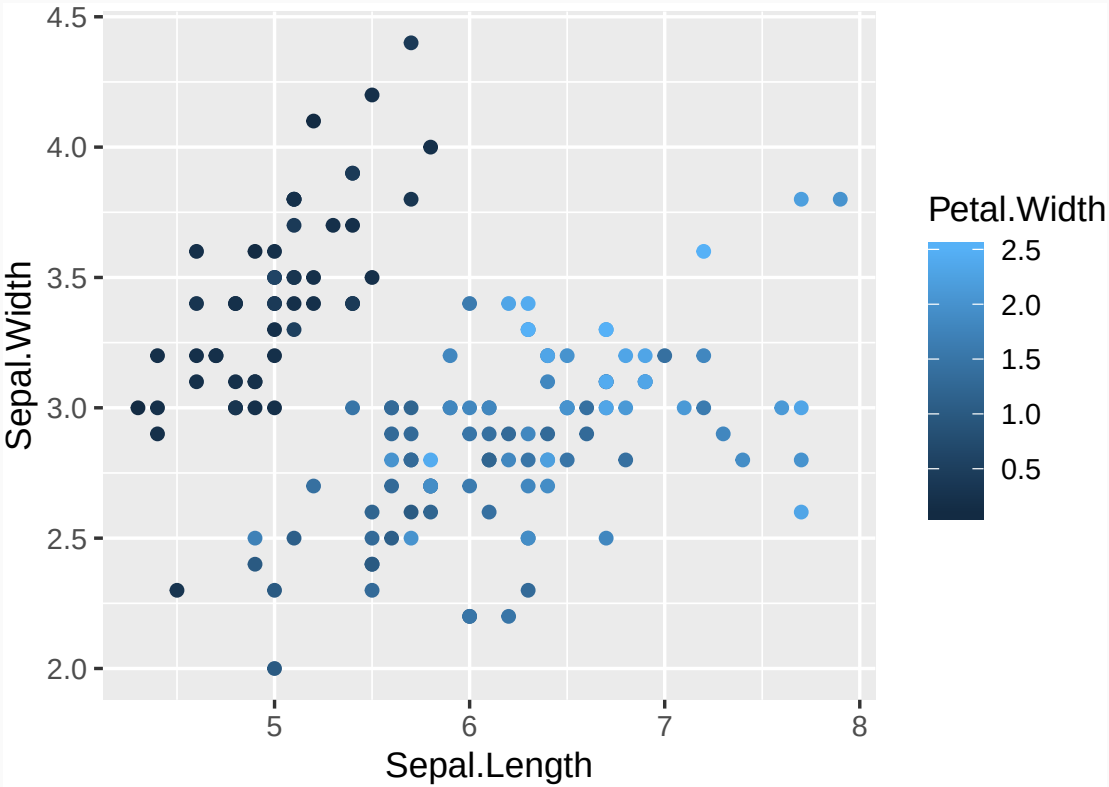

Changer la couleur

```
> ggplot(iris)+aes(x=Sepal.Length,y=Sepal.Width,
+                  color=Petal.Width)+geom_point()+
+            scale_color_continuous(low="yellow",high="red")
```

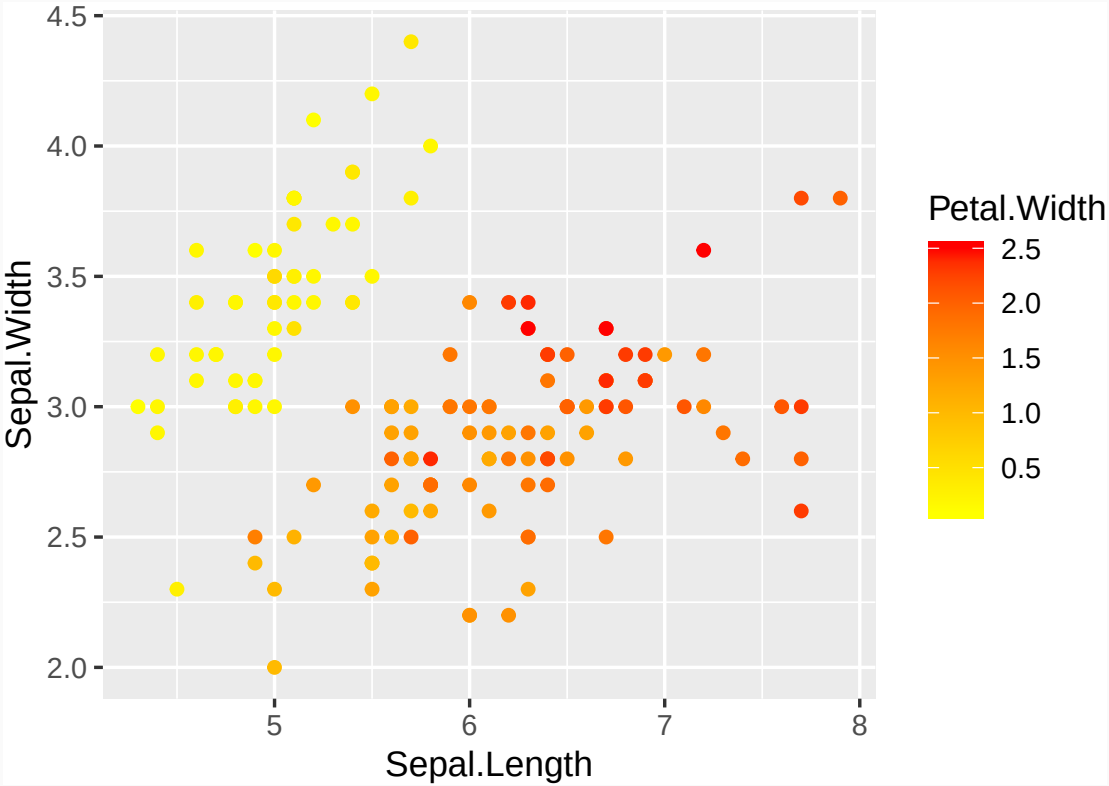

Histogramme

```
> ggplot(iris)+aes(x=Sepal.Length)+geom_histogram(fill="red")
```

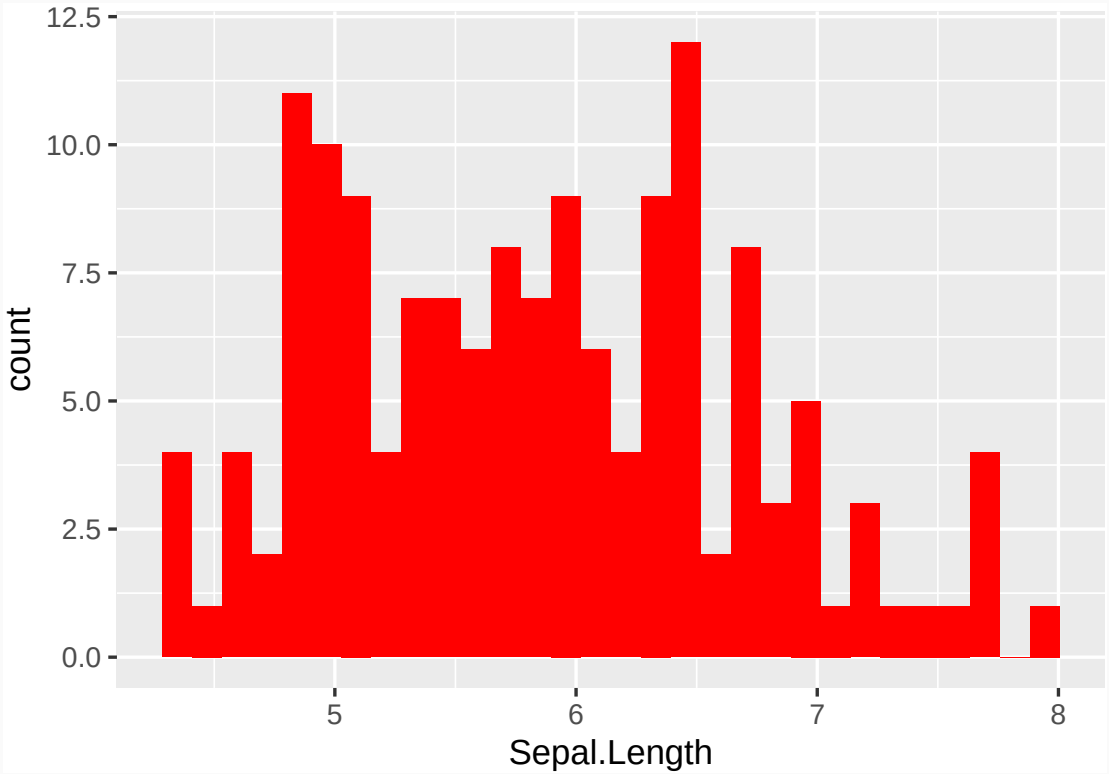

Diagramme en barres

```
> ggplot(iris)+aes(x=Species)+geom_bar(fill="blue")
```

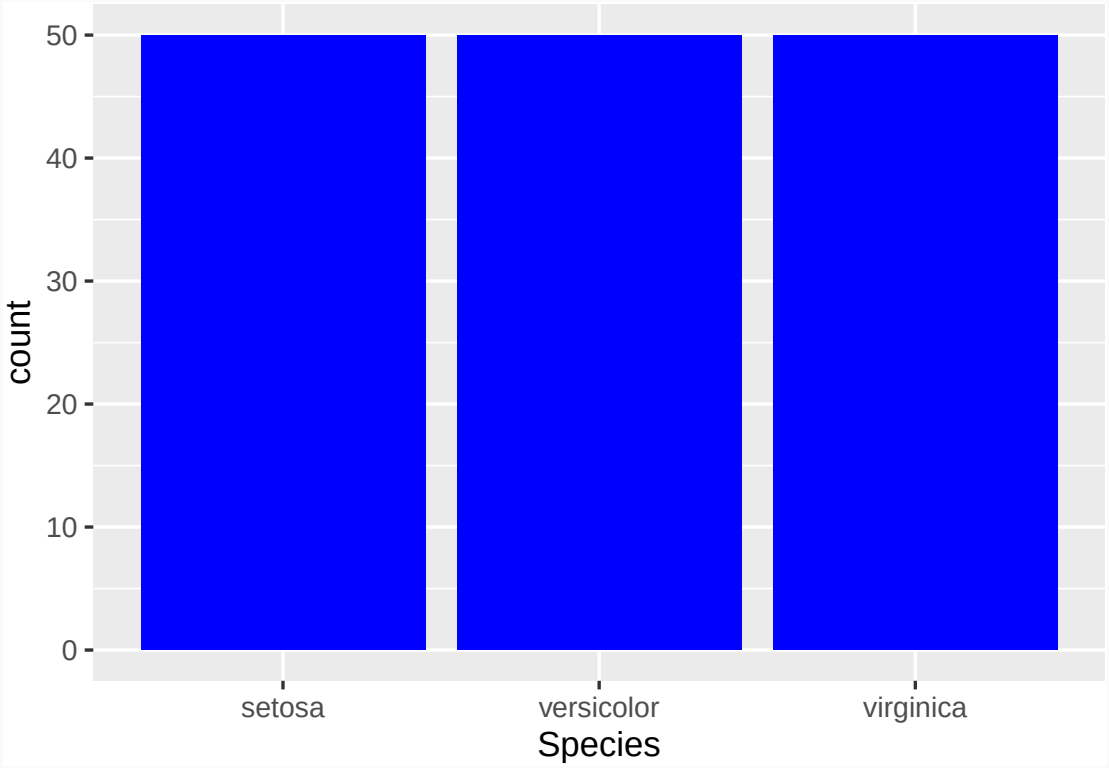

Facetting (plus compliqué)

```
> ggplot(iris)+aes(x=Sepal.Length,y=Sepal.Width)+geom_point()+
+       geom_smooth(method="lm")+facet_wrap(~Species)
```

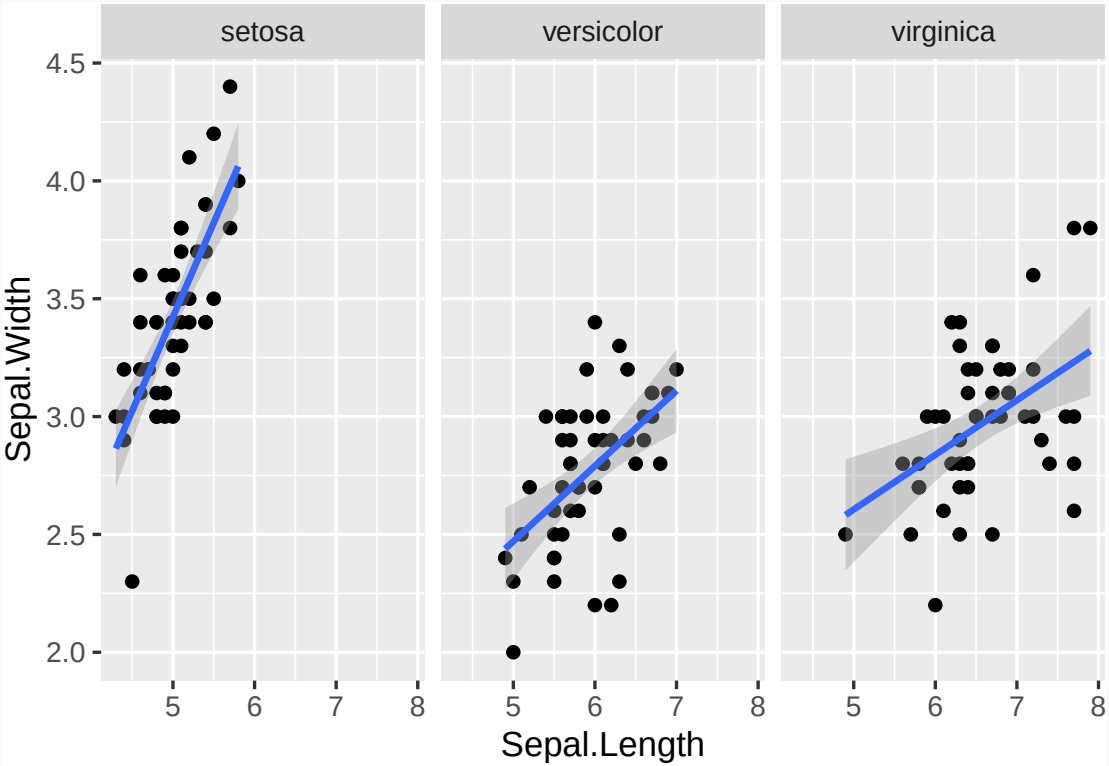

Combiner ggplot et dplyr

- Souvent important de construire un bon jeu de données pour obtenir un bon graphe.
- Par exemple

```
> head(df)
## # A tibble: 6 x 3
##    size weight.20 weight.50
##   <dbl>     <dbl>     <dbl>
## 1   153      61.2      81.4
## 2   169      67.5      81.4
## 3   168      69.4      80.3
## 4   169      66.1      81.9
## 5   176      70.4      79.2
## 6   169      67.6      88.9
```

Objectif

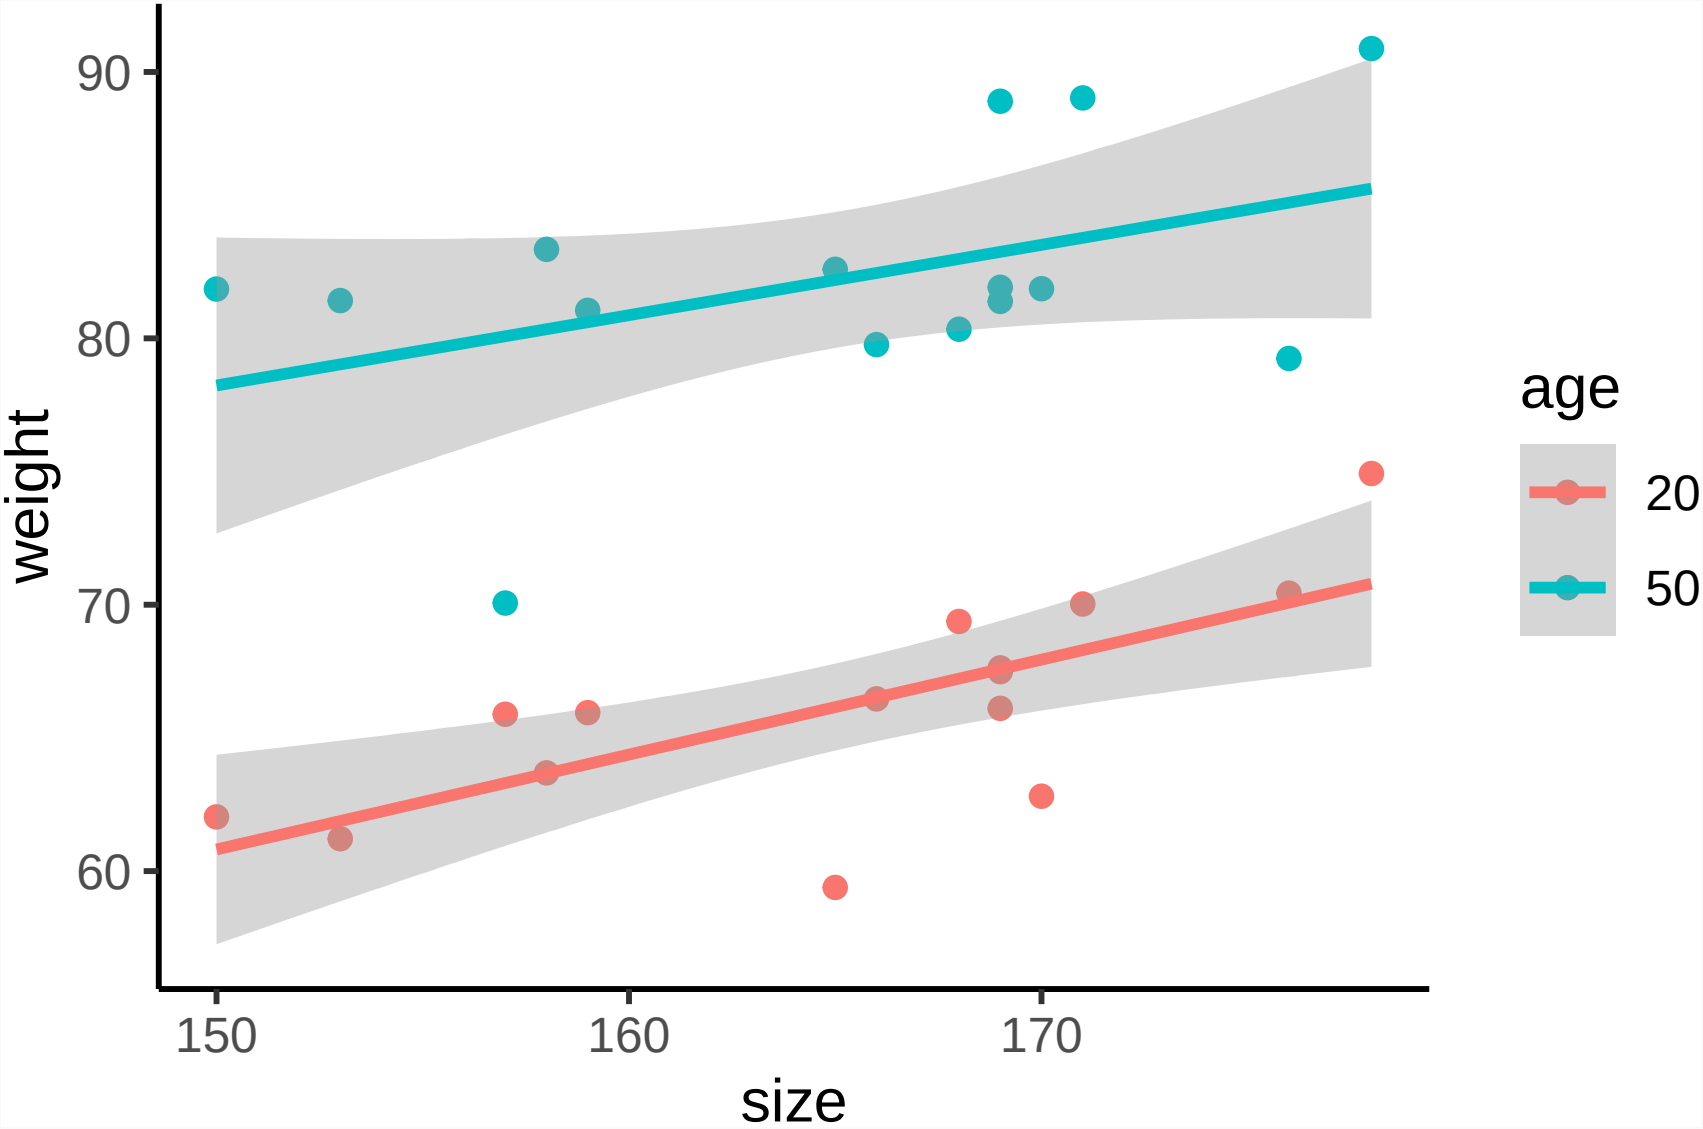

Etape dplyr

- Assembler les colonnes weight.M et weight.W en une colonne weight :

```
> df1 <- df %>% gather(key=age,value=weight,-size)
> df1 %>% head()
## # A tibble: 6 x 3
##    size age       weight
##   <dbl> <chr>      <dbl>
## 1   153 weight.20   61.2
## 2   169 weight.20   67.5
## 3   168 weight.20   69.4
## 4   169 weight.20   66.1
## 5   176 weight.20   70.4
## 6   169 weight.20   67.6
> df1 <- df1 %>% mutate(age=recode(age,
+    "weight.20"="20","weight.50"="50"))
```

Etape ggplot

```
> ggplot(df1)+aes(x=size,y=weight,color=age)+
+   geom_point()+geom_smooth(method="lm")+theme_classic()
```

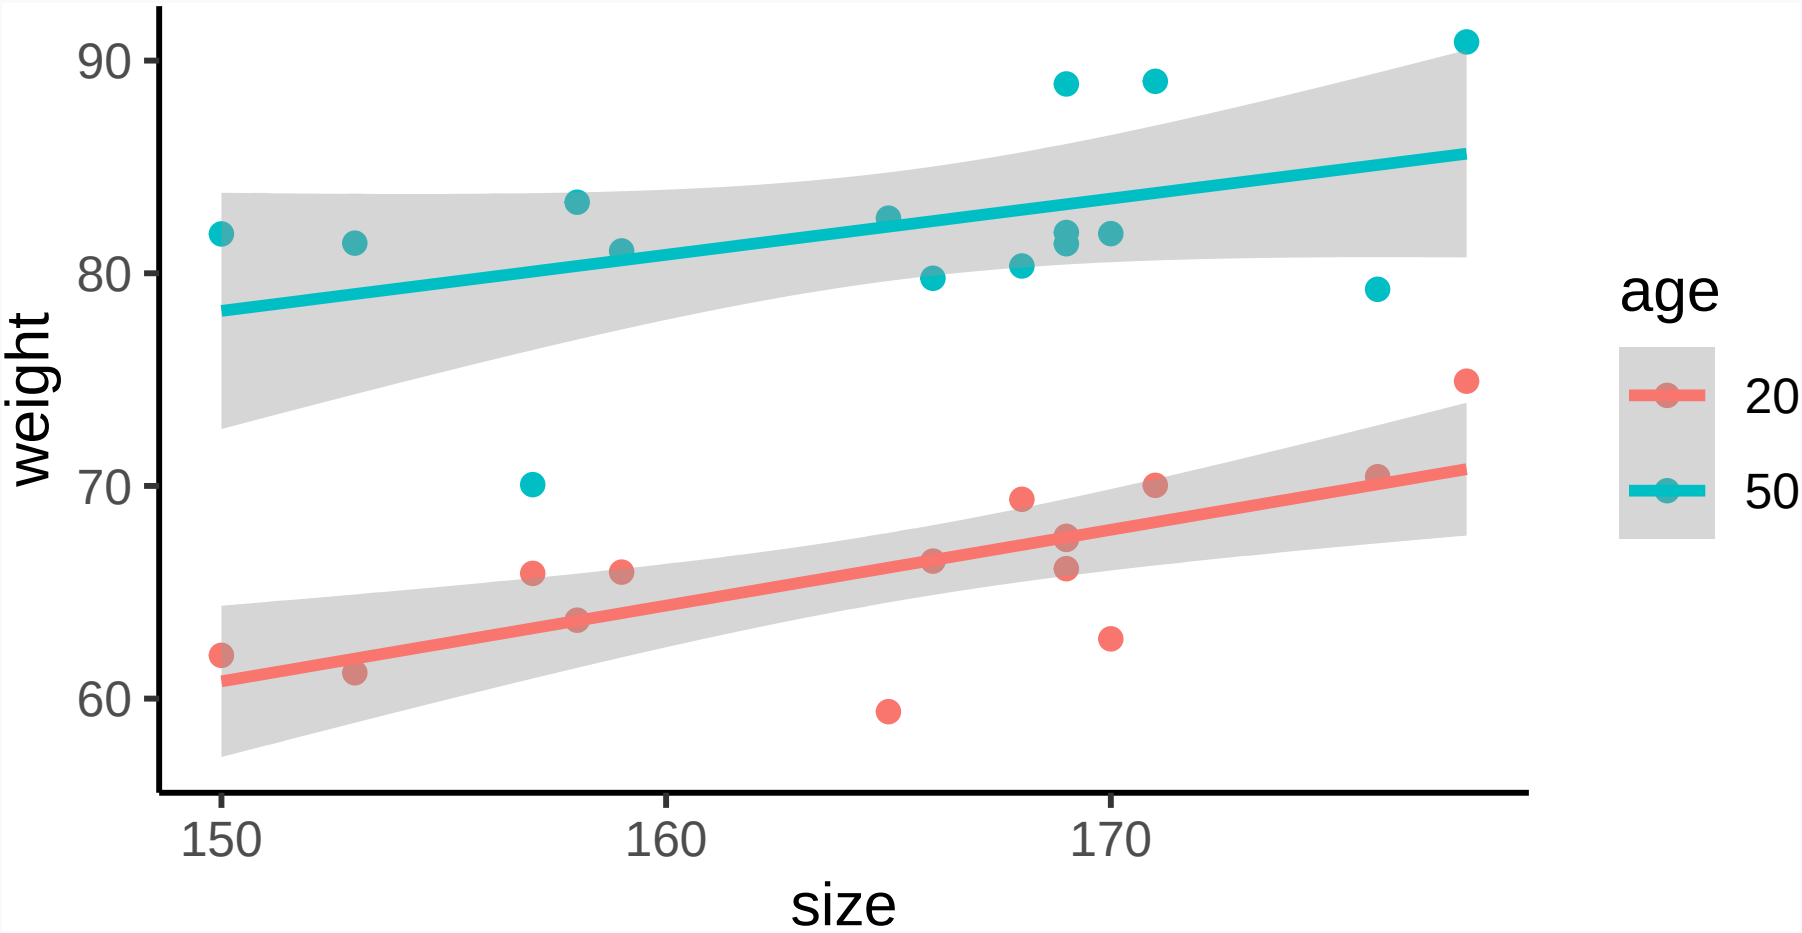

Compléments : quelques démos

```
> demo(image)
> example(contour)
> demo(persp)
> library("lattice");demo(lattice)
> example(wireframe)
> library("rgl");demo(rgl)
> example(persp3d)
> demo(plotmath);demo(Hershey)
```